


Выравнивание последовательностей: От букв к биологическим смыслам


Поиск эволюционных сигналов среди
генетического шума. Механизмы,
алгоритмы и интерпретация данных.




Зачем мы выравниваем? (Сходство vs. Гомология)

Сходство (Similarity) — это наблюдаемый математический факт.


Гомология (Homology) — это гипотеза об общем эволюционном происхождении.




- 1 Поиск консервативных доменов:** Выявление участков, критически важных для выживания





- 2 Предсказание структуры и функции:** Если белок А похож на белок Б, их функции, вероятно, схожи



- 3 Эволюционные связи:** Построение филогенетических деревьев и отслеживание мутаций



Точечная матрица (Dotplot): Визуализация совпадений



Обратная диагональ = палиндромная последовательность.

Экономика выравнивания: Штрафы и биологическая реальность

Алгоритму нужны четкие правила (штрафы) для оценки качества выравнивания (Расстояние по Левенштейну).


$$\text{Оценка} = \text{Совпадения (+)} - \text{Замены (-)} - \text{Гэпы (-)}$$



Аффинный штраф за гэн (Affine Gap Penalty)

В природе одна мутация может вставить сразу 10 нуклеотидов. Поэтому математика должна отражать биологию: «открыть» гэн стоит дорого (например, -10), а «продолжать» его стоит дешево (например, -0.5).

Матрицы замен: Не все мутации равны



PAM (Point Accepted Mutation)


Основана на эволюционной модели.
PAM1 = 1 мутация на 100 остатков.
Матрицы умножаются для больших дистанций (PAM250).

BLOSUM (Blocks Substitution Matrix)

Основана на наблюдаемых консервативных блоках.
Больше подходит для поиска удаленной гомологии.


Геометрия поиска: Глобальное vs. Локальное выравнивание.

Needleman-Wunsch /
Глобальное



Сравнение схожих по длине целых белков

Smith-Waterman /
Локальное



Поиск «иголки в стоге сена» (домены/мотивы)

Ключевой вывод: Выбор алгоритма диктуется биологической задачей. Глобальное выравнивание натягивает всю длину, локальное — ищет участки с максимальным весом совпадений.

Динамическое программирование: Путь по максимумам

Зачем строить матрицу? Для двух строк длиной 100 символов количество вариантов выравнивания больше, чем атомов во Вселенной. Мы разбиваем задачу: находим лучшее решение на каждом шаге.

30	←	16	17	18	19	20	21	22	23	24	25
17	81	74	16	17	10	6	4	3	0	1	0
3	17	27	89	25	18	10	5	4	3	3	0
0	3	11	23	83	26	18	13	6	5	4	1
0	0	9	14	36	78	33	16	13	8	6	0
0	0	9	11	19	34	76	37	16	12	12	↑
0	0	6	8	11	15	37	84	40	22	16	
0	0	6	6	8	10	24	33	73	45	34	
0	0	3	7	6	12	18	32	40	73	94	
0	0	2	8	9	10	18	21	36	58	100	

Диагональ =
Совпадение / Замена

Горизонталь =
Гэп в верхней строке

Вертикаль =
Гэп в боковой строке

**Обратный ход
(Traceback)**
гарантирует
математически
оптимальное
выравнивание при
заданных штрафах.

Задание 1: «Бумажный биоинформатик»

Заполните матрицу глобального выравнивания вручную и найдите обратный путь.

Data Panel

Последовательность 1: A G T G

Последовательность 2: A C G

Штрафы: Совпадение = +2; Замена = -1;

Пропуск = -2.

Пробуем:

	-	A	A	T	G
-	0				
A					
T					
G					

	-	A	G	T	G
-	0	-2	-4	-6	-8
A	-2	2	0	-2	-4
C	-4	0	1	-1	-3
G	-6	-2	2	0	1

Result Reveal

Выравнивание:


A G T G

A - C G

Итоговый балл (Score): 1

BLAST: Эвристика и скорость

Глобальное выравнивание с миллионами последовательностей требует слишком много времени. BLAST жертвует абсолютной точностью ради колоссальной скорости.



Вместо полного сравнения, BLAST ищет короткие точные совпадения и расширяет их, пока оценка (Score) не начнет падать.



Basic Local Alignment Search Tool

BLAST finds regions of similarity between biological sequences. The program compares nucleotide or protein sequences to sequence databases and calculates the statistical significance.

[Learn more](#)

NEWS


Mon, 21 Jul 2025

Here are a few highlights in our latest BLAST+ release:

Download BLAST+ 2.17.0 now!

[More BLAST news...](#)

Web BLAST



BLAST Genomes

Enter organism common name, scientific name, or tax id

Search

[Human](#)

[Mouse](#)


[Rat](#)

[Microbes](#)

<https://blast.ncbi.nlm.nih.gov/Blast.cgi>

E-Value: Значимость или случайность?

E-value показывает, сколько совпадений с такой же **оценкой (Score)** можно ожидать найти в базе данных **чисто случайно**.



Правила интерпретации:



$E < 0.02$: Высокая вероятность настоящей гомологии.



$0.02 < E < 1$: Гомология не очевидна (серая зона).



$E > 1$: Сходство, скорее всего, случайно.

Осторожно с короткими последовательностями! Сходство может быть не случайным даже при $E > 1$ (например, калиотоксин и дефензин).

Вероятностный скачок: Скрытые марковские модели (HMM).

BLAST/Матрицы



Поиск слов

Ищет точные символьные совпадения.
Не видит структурного контекста.

HMM





Понимание грамматики

Переход от «символов» к «состояниям».
Понимает, какая химическая функция требуется в конкретной позиции.

HMM учитывает, что в активном центре фермента замена критична (огромный штраф), а на периферийной петле — допустима.

Multiple Sequence Alignment

Множественное выравнивание (MSA) – попытка восстановить историю эволюции. HMM превращает MSA в «умный профиль»



MUSCLE

Multiple Sequence Alignment (MSA)

[Home](#) [Help & Privacy](#) [Recent Jobs](#) **[Input Form](#)**

Feedback 

Welcome to the Job Dispatcher website! If you need assistance or have feedback, please [contact](#) us.



MUSCLE stands for Multiple Sequence Comparison by Log-Expectation. MUSCLE is claimed to achieve both better average accuracy and better speed than ClustalW2 or T-Coffee, depending on the chosen options. This tool can align up to 500 sequences or a maximum file size of 1 MB.

Input sequence 

Paste your sequence here - or use the example sequence


Выберите файл Файл не выбран

Use the example

Clear sequence

[More example inputs](#)

Профильные HMM: Учет позиционной специфичности.



Профильные HMM превращают MSA в «умный» фильтр. Они знают, в какой именно позиции замена допустима, а в какой — строго запрещена.

Это золотой стандарт классификации белков. База данных **Pfam** построена исключительно на HMM, позволяя находить «глубокую» гомологию, которую не видит BLAST.

Как это работает?

Start with a multiple sequence alignment




Insertions / deletions can be modelled



Occupancy and amino acid frequency at each position in the alignment are encoded



Profile created



EMBL-EBI

HMMER

Biosequence analysis using profile hidden Markov Models

Search →

Perform searches using HMMER

Results →

View your previous search results

Software →

Download latest HMMER packages

Help →

Info about using the HMMER website

About →

Contact →

About HMMER

The HMMER web server: fast and sensitive homology searches. This site has been designed to provide near interactive searches for most queries, coupled with intuitive and interactive results visualisations.

Сравнительная матрица алгоритмов (Cheat Sheet)

Метод	Когда использовать	Плюсы	Минусы
Глобальное (NW)	Схожие по длине белки	Точность 	Медленно на длинных данных
Локальное (SW)	Поиск доменов/мотивов	Находит частичные совпадения	Ресурсозатратно
BLAST	Поиск по огромным базам	Скорость (секунды) 	Пропускает далеких родственников
HMM	Поиск семейств белков	Видит глубокую гомологию 	Требует качественного MSA для обучения

Диагностика ошибок: Биологический «шум» и ловушки.


Красивое выравнивание $\neq$ биологически верное выравнивание. Алгоритм не знает контекста.

Низкая сложность




Участки низкой сложности могут дать высокий балл без реальной гомологии (требуют маскирования).

Доменная перетасовка




Изменение порядка доменов разрушает глобальные алгоритмы выравнивания

Сдвиг рамки



Одиночная делеция вызывает сдвиг всей рамки считывания, полностью ломая выравнивание.

Ошибка интерпретации: Ловушка E-value.



E-value — это не вероятность гомологии. Это ожидаемое количество случайных совпадений с таким же баллом при поиске в базе данного размера. Алгоритм выравнивает гемоглобин с текстом «Гамлета», если вы его попросите.

Чек-лист аналитика: Как читать выравнивание.

1. Длина выравнивания

Не слишком ли оно короткое относительно полных белков?

2. Структурный контекст

Не разбивают ли гэпы альфа-спирали или бета-листы?


3. Биологические маркеры

Сохранены ли ключевые аминокислоты? (например, проксимальный гистидин His-93 в гемоглобине).

4. Эволюционная дистанция


Соответствует ли процент идентичности таксономическому родству?

Всегда проверяйте математический оптимум биологическим смыслом.



Задание 2: BLAST неизвестной последовательности

Запустите поиск последовательности данного белка в BLAST и HMMER



1. Что это за белок? Какому организму принадлежит?
2. Каков E-value лучшего совпадения?
3. Какому домену соответствует последовательность?

Задание 3: MSA и поиск консервативности

Откройте **EMBL-EBI Muscle** или **Clustal Omega**. Выровняйте предоставленные последовательности гемоглобина (Human, Horse, Carp).

```
>sp|P69905|HBA_HUMAN Hemoglobin subunit alpha OS=Homo sapiens
MVLSPADKTNVKAAWGKVGAHAGEYGAEALERMFLSFPTTKTYFPHFDLSHGSAQVKGHGKKVADALTNAVAHVDDMPNALSALSDDLHAHKL
RVDPVNFKLLSHCLLVTLAAHLPAEFTPAVHASLDKFLASVSTVLTISKYR
>sp|P01958|HBA_HORSE Hemoglobin subunit alpha OS=Equus caballus
MVLAAADKTNVKAAWSKVGGHAGEYGAEALERMFLGFPTTKTYFPHFDLSHGSAQVKAHGKKVGDALTAVGHLLDLPGLSNLSDLLHAHKL
RVDPVNFKLLSHCLLSTLAVHLPNDFTPAVHASLDKFLSSVSTVLTISKYR
>sp|P01945|HBA_CYPKA Hemoglobin subunit alpha OS=Cyprinus carpio
MSLSDKDKA AVKGLWAKISPKADDIGAEALGRMLTVYPQTKTYFSHWADLSPGSGPVKKHGGIIMGAIGKAVGLMDDLKGALAELSSELHAFKL
RVDPANFKILSHNIVVTIACLGEPFTPEVHVSLDKFLAAVSTVLTISKYR
```

Biological Objective

Гемоглобин связывает железо с помощью гистидина (His/H). Найдите наиболее консервативные столбцы с буквой H в вашем выравнивании. Одинаково ли их положение у человека и карпа?