


От гена к дереву: Реконструкция эволюционной истории


Графы, алгоритмы и пайплайн
филогенетического анализа.

MGDVEKGKKIFIMKCSQCHTVEK

A phylogenetic tree diagram. At the bottom left, a single sequence 'MGDVEKGKKIFIMKCSQCHTVEK' is shown. A line extends from this sequence and branches into a complex tree structure that moves towards the top right. The tree consists of several internal nodes and terminal branches, representing evolutionary relationships.


Эпидемиология

Поиск источника и отслеживание мутаций штаммов вирусов (напр., эволюция линий SARS-CoV-2).




Эволюционная биология

Разрешение спорных вопросов систематики и реконструкция истории расхождения видов.



Функциональная аннотация


Изучение новых генов, предсказание функций белков и выявление консервативных сайтов связывания.





SEQ_001 : MKT...H-G-S-X...VLA

Математическая основа: От графа к дереву

Эволюционное дерево — это частный случай связного ациклического графа. Мы переводим биологическую историю в строгую математическую модель.




Ненаправленный граф
с циклами




Связный ациклический граф
(Дерево)

Анатомия филогенетического дерева


Каждая линия и точка на графе имеет конкретный биологический смысл — от современных организмов до их давно вымерших предков.





Кладограмма

Акцент исключительно на топологию (кто кому родственник). Длина линий не имеет математического смысла.



Филограмма

Длина ветвей пропорциональна количеству накопленных эволюционных изменений. Показывает скорость эволюции разных линий.


Три кита филогенетики:

Выбор алгоритма

Не существует идеального метода. Выбор алгоритма — это всегда компромисс между скоростью вычислений и эволюционной точностью.

Семейство	Алгоритмы	Принцип работы	Плюсы/Минусы
Дистанционные	UPGMA, Neighbor-Joining (NJ)	Считают попарные расстояния, строят матрицу, кластеризуют.	Максимально быстрые, но теряют часть информации. 
Максимальной экономии	Maximum Parsimony (MP)	Ищут дерево с минимальным числом мутаций.	Интуитивно понятны, но подвержены артефакту длинных ветвей.
Вероятностные (Золотой стандарт)	Maximum Likelihood (ML), Bayesian Inference (BI)	Используют модели эволюции (Jukes-Cantor, GTR) для поиска наиболее вероятного дерева.	Самые точные, учитывают скорость мутаций, но требуют серверов. 

Оценка достоверности: Анатомия Bootstrap



Ресемплинг: алгоритм создает тысячи псевдовыборок из исходного выравнивания и строит дерево для каждой. Bootstrap-значение — это процент деревьев, в которых сохранился данный узел.



>90 : Высокая уверенность. Ветвь надежна.



70-90 : Средняя поддержка. Требуется внимания.



<70 : Зона сомнений. Топология в этом узле может быть случайной.

Язык филогенетики: Форматы данных


Входные данные (FASTA)

```
>Homo_sapiens ←  
MGDVEKGGKKIFIMKCSQCHTVEKGGKHKKTGPNLHGLF...
```

Знак > обозначает идентификатор таксона, далее следует сырая аминокислотная последовательность.




Выходные данные (Newick)

```
(A:0.1,B:0.2,(C:0.3,D:0.4):0.5);
```



Топология графа сохраняется в виде вложенных скобок. Числа после двоеточия — длина ветви.

Пайплайн исследования: Эволюция Цитохрома С



1. Сбор данных

2. Выравнивание
(MSA)

3. Построение
(ML)

4. Визуализация

(NCBI BLAST /
Поиск гомологов)

(MUSCLE /
Сопоставление
колонок)

(IQ-TREE /
Подбор модели)

(iTOL / Укоренение
и рендер)

Шаг 1: Формирование датасета и выбор Outgroup

Целевой белок: Цитохром С (высококонсервативный белок дыхательной цепи).

Приматы:	<i>Homo sapiens</i>
Грызуны:	<i>Mus musculus</i>
Птицы:	<i>Gallus gallus</i>
Амфибии:	<i>Xenopus laevis</i>
Рыбы:	<i>Danio rerio</i>
Насекомые:	<i>Drosophila melanogaster</i>

Внешняя группа (Outgroup):

Saccharomyces cerevisiae
(Дрожжи).

Зачем? Максимально далекий гомолог. Необходим для корректного укоренения графа на финальном этапе и задания вектора времени.

Сиквенсы по
ссылке:

https://drive.google.com/file/d/1XBlwIVeRZStRM6ZD_128ktX2-QLGEmaW/view?usp=sharing

Шаг 2: Множественное выравнивание (MUSCLE)

	MGDVEKGKKIFIMKCSQCHTVEK
Homo_sapiens	MGDVEKGKKIFVQKCAQCHTVEK
Mus_musculus	MGDVEKGKKIFVQKCAQCHTVEK
Gallus_gallus	MGDIEKGKKIFVQKCSQCHTVEK
Xenopus_laevis	MGDVEKGKKIFVQKCAQCHTCEK


Смысл операции:

Алгоритм вставляет гэпы (пропуски), чтобы гомологичные аминокислоты встали в единые вертикальные колонки.

Правило:


Мы должны сравнивать только эволюционно эквивалентные позиции (сравниваем «яблоки с яблоками»). Консервативные участки служат надежными якорями для алгоритма.

Шаг 3: Построение дерева Maximum Likelihood




Шаг 4: Визуализация и укоренение (iTOL)

До (Unrooted)



Неукорененное дерево. Показывает дистанцию, но не имеет направления времени.

После (Rooted)



Укоренение по Outgroup. Выбор дрожжей в качестве корня придает графу эволюционный вектор — от древности к современности.

Интерпретация результата: Чтение эволюции



1. Совпадает ли ветвление с классической систематикой?
2. Что указывает на количество накопленных мутаций?
3. Что можно сказать об устойчивости узлов на основании значений bootstrap?

Практическое задание по пройденным темам

- Доступно по ссылке:
https://docs.google.com/document/d/1MZWkcTu_UYJslz6pSSadXHcDxaJ_DAgwEkC98v7aS4c/edit?usp=sharing
- Дедлайн: 29 марта 23:59