

# ВВЕДЕНИЕ В БИОИНФОРМАТИКУ

## Лекция №4

Значимость выравнивания. Экспресс-сравнение  
последовательностей. Множественное  
выравнивание. Филогенетические деревья

Новоселецкий Валерий Николаевич  
к.ф.-м.н., доц. каф. биоинженерии  
[valery.novoseletsky@yandex.ru](mailto:valery.novoseletsky@yandex.ru)

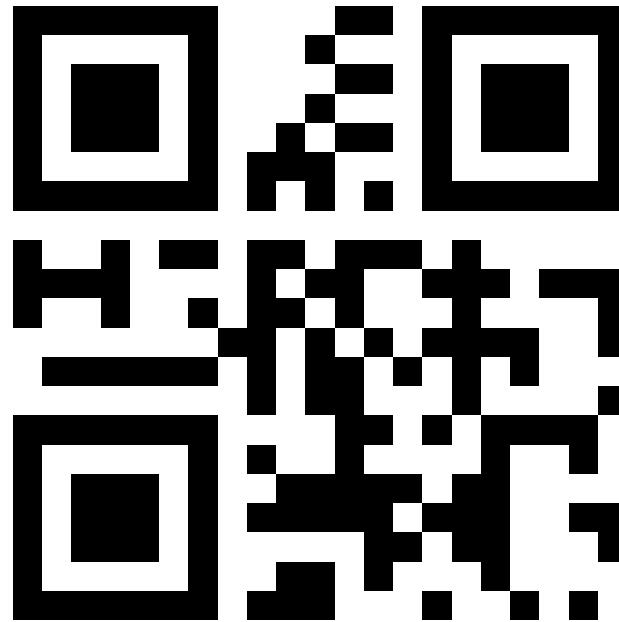
Сайт курса <http://intbio.org/bioinf2018>

# Контроль посещаемости сегодня

Заполнить форму по адресу

<http://intbio.org/4>

возможность закрывается сразу после перерыва



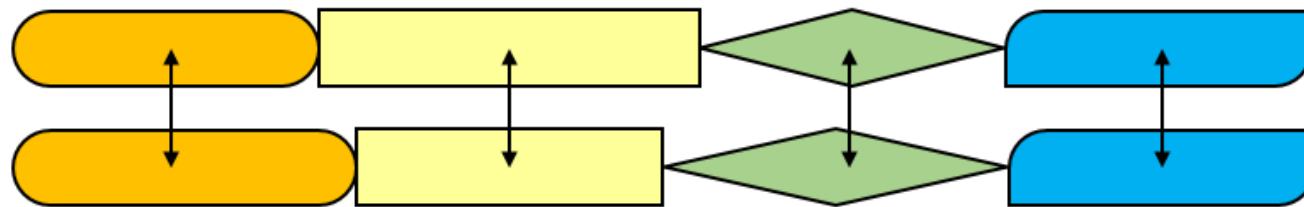
либо

записаться в список на перерыве

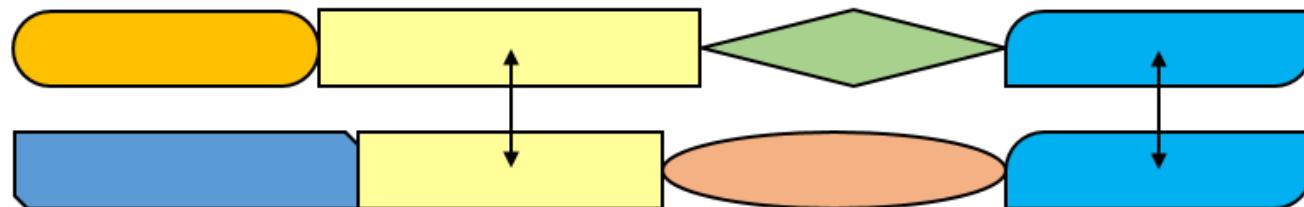
# Расчет выравнивания двух последовательностей.

## Алгоритм Смита-Уотермана (1981)

- модификация алгоритма Нидлмана-Вунша с аффинным штрафом за вставку и обнулением отрицательных значений в матрице – позволяет выявлять локальные выравнивания.



Global Alignment



Local Alignment

# Расчет выравнивания двух последовательностей.

## Алгоритм Смита-Уотермана

|     | "-" | g | c   | t   | g | a   | a   | c   | g | match | mut | gap |
|-----|-----|---|-----|-----|---|-----|-----|-----|---|-------|-----|-----|
| "-" | 0   | 0 | 0   | 0   | 0 | 0   | 0   | 0   | 0 | 0,5   | -1  | -1  |
| c   | 0   | 0 | 0,5 | 0   | 0 | 0   | 0   | 0,5 | 0 |       |     |     |
| t   | 0   | 0 | 0   | 1   | 0 | 0   | 0   | 0   | 0 |       |     |     |
| a   | 0   | 0 | 0   | 0   | 0 | 0,5 | 0,5 | 0   | 0 |       |     |     |
| t   | 0   | 0 | 0   | 0,5 | 0 | 0   | 0   | 0   | 0 |       |     |     |
| a   | 0   | 0 | 0   | 0   | 0 | 0,5 | 0,5 | 0   | 0 |       |     |     |
| a   | 0   | 0 | 0   | 0   | 0 | 0,5 | 1   | 0   | 0 |       |     |     |
| t   | 0   | 0 | 0   | 0,5 | 0 | 0   | 0   | 0   | 0 |       |     |     |
| c   | 0   | 0 | 0,5 | 0   | 0 | 0   | 0   | 0,5 | 0 |       |     |     |

# Пример выравнивания двух последовательностей. EMBOSS Needle

STEP 1 - Enter your protein sequences

Enter or paste your first protein sequence in any supported format:

```
>Protein1_name
QWERTYASDFGH
```

Or, upload a file: Выберите файл Файл не выбран

AND

Enter or paste your second protein sequence in any supported format:

```
>Protein2_name
WERTYASDFGHK
```

STEP 2 - Set your pairwise alignment options

The default settings will fulfill the needs of most users.

More options... (Click here, if you want to view or change the default settings.)

STEP 3 - Submit your job

Be notified by email (Tick this box if you want to be notified by email when the result is ready)

**Submit**

```
# Aligned_sequences: 2
# 1: Protein1_name
# 2: Protein2_name
# Matrix: EBLOSUM62
# Gap_penalty: 10.0
# Extend_penalty: 0.5
#
# Length: 13
# Identity: 11/13 (84.6%)
# Similarity: 11/13 (84.6%)
# Gaps: 2/13 (15.4%)
# Score: 67.0
#
=====
Protein1_name 1 QWERTYASDFGH- 12
          ||||||| |
Protein2_name 1 -WERTYASDFGHK 12
```

# Значимость выравнивания

Насколько значимо полученное выравнивание?

Имеет ли оно биологический смысл или образовалось случайно?

|          |     |  |     |
|----------|-----|--|-----|
| SEQUENCE | 1   | VLSAADKTNVKAAWSKGHHAGEYGAELERMFLGFPTTKTYFPHFDLSH   | 50  |
|          |     | .       . .    .       . .                         |     |
| SEQUENCE | 1   | VLSPADKTNVKAAWGKVGAHAGEYGAELERMFLSFPTTKTYFPHFDLSH  | 50  |
|          |     | .       .  .  .  :  : .  .  :                      |     |
| SEQUENCE | 51  | GSAQVKAHGKKVADGLTLAVGHLDLPGALSDLNSNLHAHKLRVDPVNFKL | 100 |
|          |     | .       .  .  .  :  : .  .  :                      |     |
| SEQUENCE | 51  | GSAQVKGHGKKVADALTNAVAHVDDMPNALSALSDLHAHKLRVDPVNFKL | 100 |
|          |     | .    .    .  :       :                             |     |
| SEQUENCE | 101 | LSHCLLSTLAVHLPNDFTPASVHASLDKFLSSVSTVLTSKYR         | 141 |
|          |     | .    .    .  :       :                             |     |
| SEQUENCE | 101 | LSHCLLVTLAAHLPAEFTPASVHASLDKFLASVSTVLTSKYR         | 141 |
|          |     | .    .  :  |     |

```
# Matrix: EBLOSUM62
# Gap_penalty: 10.0
# Extend_penalty: 0.5
#
# Length: 141
# Identity:      123/141 (87.2%)
# Similarity:    128/141 (90.8%)
# Gaps:          0/141 ( 0.0%)
```

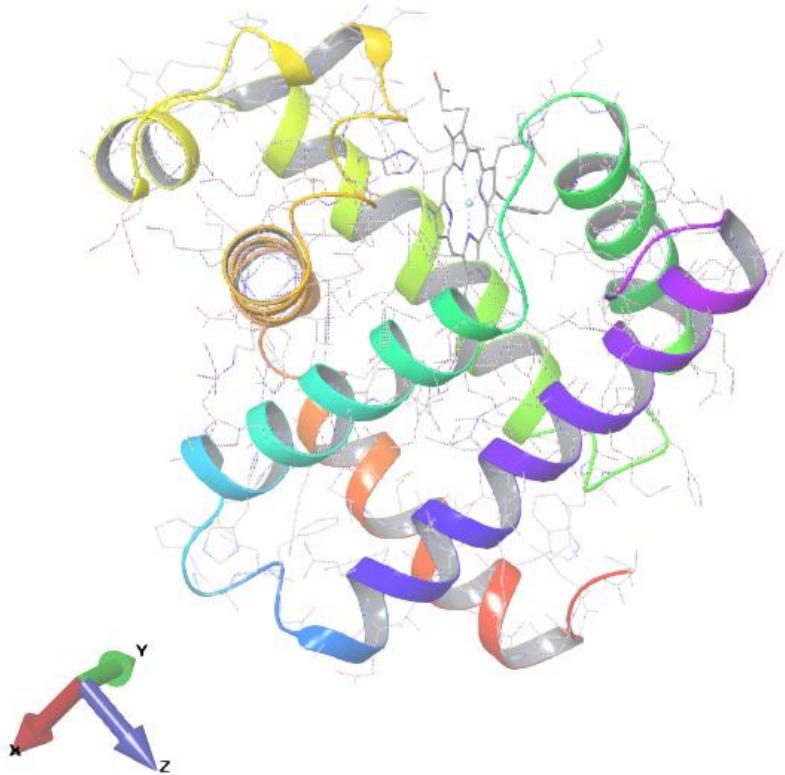
# Значимость выравнивания

|          |     |  |     |
|----------|-----|--|-----|
| SEQUENCE | 1   | -VLSEGEWQLVLHVWAKVEADVAGHGQDILIRLFKSHPETLEKFDRFKHL | 49  |
|          |     | . : .:...  .... .:.  :... ..... .:... ... . ..     |     |
| SEQUENCE | 1   | GALTESQAALVKSSWEEFNANIPKHTHRFFILVLEIAPAAK---DLFSFL | 47  |
|          |     |  |     |
| SEQUENCE | 50  | KTEAEM-KASEDLKKHGVTV-----LTALGAILKKKGHHEAELKP      | 88  |
|          |     | ...: : :...: :.. ....  ... .:.. :  .  .            |     |
| SEQUENCE | 48  | KGTSEVPQNNPELQAHAGKVFKLVYEAAIQLEVTVVVVT----DATLKN  | 92  |
|          |     |  |     |
| SEQUENCE | 89  | LAQSHATKHKIPIKYLEFISEAIIHVLHSRHPGDFGADAQGAMNKALELF | 138 |
|          |     | .... .:  ..:...:....:    :...  ..  ....: . ...:    |     |
| SEQUENCE | 93  | LGSVHVSKE-GVADAHFPVVKEAILKTIKE---VVGAKWSEELNSAWTIA | 137 |
|          |     |  |     |
| SEQUENCE | 139 | RKDIAAKY-KELGYQG 153                               |     |
|          |     | ...: ...   :....                                   |     |
| SEQUENCE | 138 | YDELAIVVIKKEMDDAA 153                              |     |

```
# Matrix: EBLOSUM62
# Gap_penalty: 10.0
# Extend_penalty: 0.5
#
# Length: 166
# Identity:      35/166 (21.1%)
# Similarity:    62/166 (37.3%)
# Gaps:          26/166 (15.7%)
```

# Значимость выравнивания

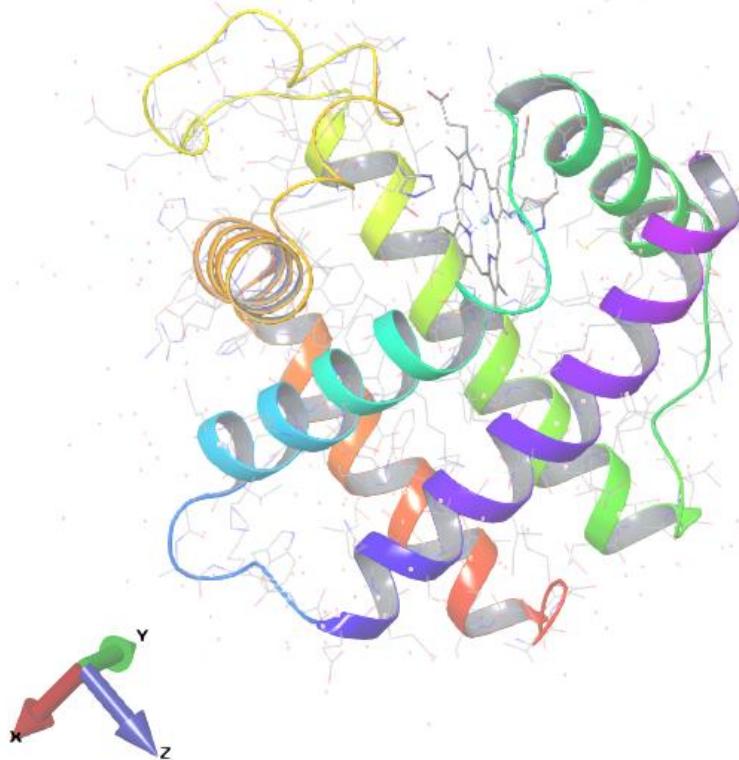
Title: 1MBN  
PDB ID: 1MBN



Миоглобин кашалота (1mbn, 1969)

What about Impossible Burger? ☺

Title: 1GDJ  
PDB ID: 1GDJ



Леггемоглобин люпина (1gdj, 1995) (ИК РАН)

<https://impossiblefoods.com/>

# Значимость выравнивания

миоглобин кашалота и леггемоглобин люпина

Идентичность 18%\*, но родство подтверждается сходством структуры и функции

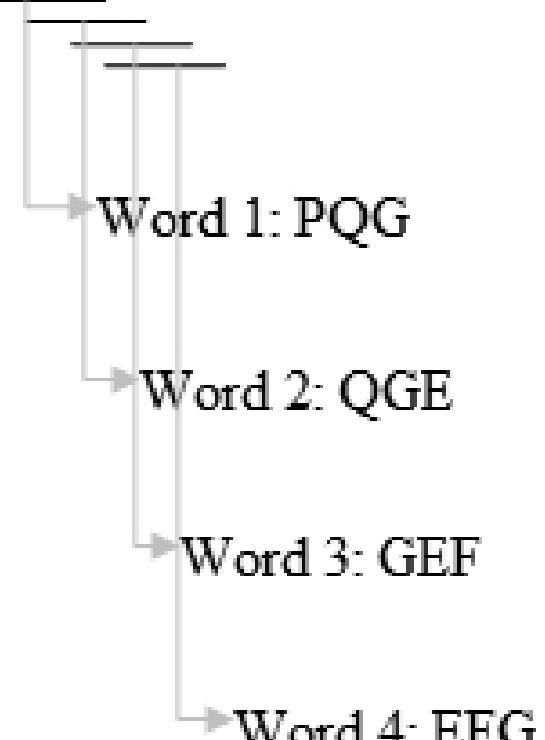
# Экспресс-методы сравнения последовательностей. BLAST

BLAST - Basic Local Alignment Search Tool (Altschul et al., 1990) предназначен для сравнения новых последовательностей с уже содержащимися в базах данных.

Query sequence: PQGEFG

Алгоритм:

- Удаление малоинформативных участков последовательности (повторы и т.п.);
- Составление списка  $k$ -буквенных слов ( $K$ -tuple), присутствующих в последовательности запроса;
- Сопоставление этих слов со всеми возможными словами длины  $k$  и оценка сходства; отбор слов с оценкой, превышающей пороговую (например, для слова PQG сходными будут PNG, PEG и PDG, но не PQW)
- Сканирование последовательности из БД и поиск в ней слов с высокой оценкой, полученных на предыдущем шаге;



# Экспресс-методы сравнения последовательностей. BLAST

- Расширение локальных выравниваний в обе стороны до тех пор, пока суммарная оценка выравнивания не начинает уменьшаться (построение сегментных пар (high-scoring segment pair, HSP));

Query sequence: R P P Q G L F  
Database sequence: D P P E G V V

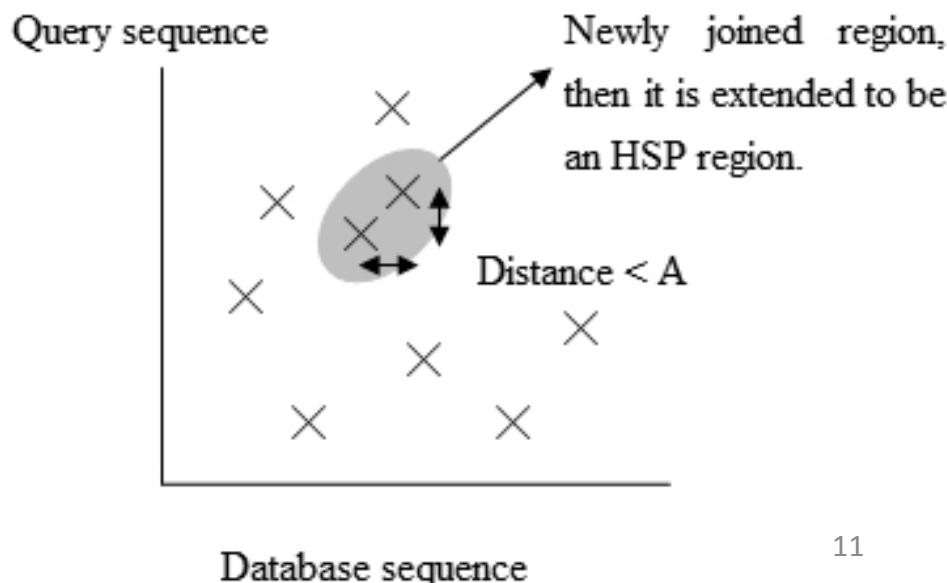
Score: -2 7 7 2 6 1 -1

Optimal accumulated score =  $7+7+2+6+1 = 23$

Exact match is scanned.

HSP

- Объединение сегментных пар, лежащих на удалении меньше A;
- Составление списка сегментных областей с высокой оценкой;
- Расчет статистической значимости этих оценок.



# BLAST. Значимость выравнивания

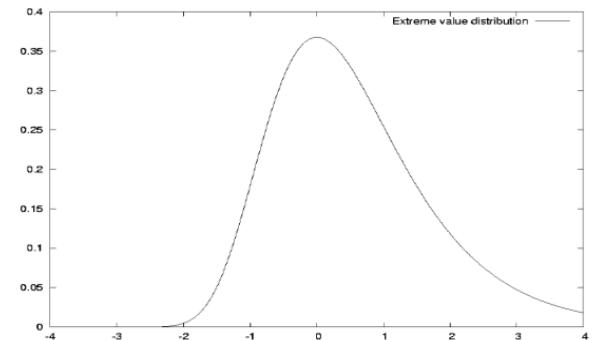
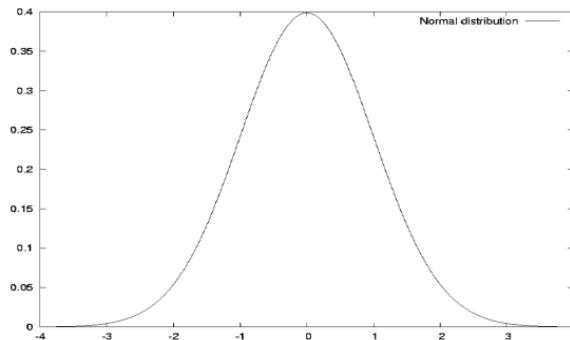
$$\tilde{S}_{n,m} = S_{n,m} - \frac{\ln(nm)}{\lambda}$$

↑  
Распределение нормализованных максимальных оценок НСП подчиняется распределению Гумбеля (распределению экстремальных значений, Gumbel, 1937; Гнеденко, 1943), для которого

$$P\left(\tilde{S}_{n,m} > S\right) \approx 1 - \exp\left(-K m n e^{-\lambda S}\right) \approx K m n e^{-\lambda S}$$

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{x^2}{2}}$$

$$\varphi(x) = e^{-x} \cdot e^{-e^{-x}}$$



# BLAST. Значимость выравнивания

$$P(\tilde{S}_{n,m} > S) \cdot m \equiv E-value$$

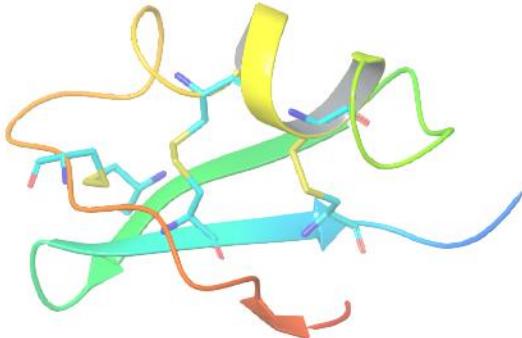
|                |                               |
|----------------|-------------------------------|
| $E < 0,02$     | высокая вероятность гомологии |
| $0,02 < E < 1$ | гомология не очевидна         |
| $E > 1$        | сходство случайно             |

Для коротких последовательностей сходство может быть НЕ случайным даже при  $E > 1$  !!

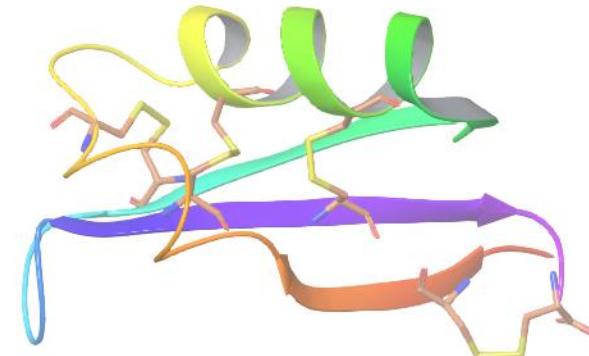
Пример: поиск в PDB по последовательности калиотоксина дает, среди прочего, неожиданный результат:

```
>lcl|PDB:1TI5_A mol:protein length:46 plant defensin Length=46
Score = 25.8 bits (74), Expect = 1.9
Identities = 12/31 (39%), Positives = 14/31 (45%), Gaps = 2/31 (6%)
Query    7 KCSGSPQCLKPCKDAGMRFKGKC--MNRKCHC 35  калиотоксин
          KC      C   CK+ G G   C   M R C+C
Sbjct 12 KCLIDTTCAHSCKNRGYIGGNCKGMTRTCYC 42  дефензин
```

# BLAST. Значимость выравнивания



калиотоксин



дефензин

|        |   |    |
|--------|---|----|
| 3ODV_T | 1 -GVE INV----KCSGSPQCLKPC <sup>K</sup> DAGMR FGKCM-N-RKCHC <sup>T</sup> TPK-   | 38 |
| 1TI5_A | 1 RT <sup>C</sup> M <sup>I</sup> KKE GWGKCL IDTTCAHSC <sup>K</sup> N <sup>R</sup> GYI GGNCKGMTR <sup>T</sup> CYC <sup>L</sup> VNC | 46 |
|        | * :            ** .    * :    ** : *    * : *    * * : *    :   |    |

>lcl|PDB:1TI5\_A mol:protein length:46 plant defensin Length=46

Score = 25.8 bits (74), **Expect = 1.9**

Identities = 12/31 (39%), Positives = 14/31 (45%), Gaps = 2/31 (6%)

Query 7 KCSGSPQCLKPC<sup>K</sup>DAGMR FGK<sup>C</sup>--MNRKCHC 35    калиотоксин  
          KC            C    CK+ G G    C    M R C+C

Sbjct 12 KCLIDTTCAHSCKN<sup>R</sup>GYI GGNCKGMTR<sup>T</sup>CYC 42    дефензин

# Множественное выравнивание последовательностей

Что полезного?

- Выявление удаленной гомологии
- Выявление консервативных остатков и мотивов
- Построение филогенетических деревьев
- ...

Алгоритмы:

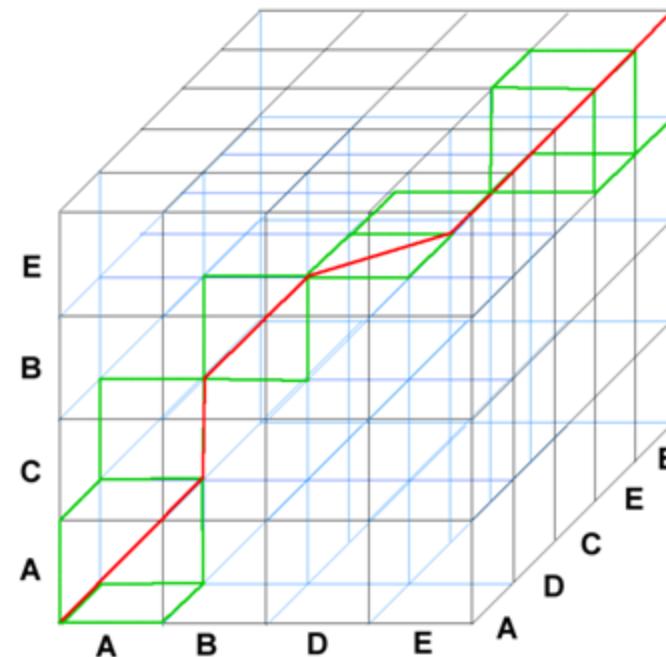
- Динамическое программирование
- Построение профилей
- Прогрессивное выравнивание
- Итеративные методы
- Скрытые марковские модели
- Квантовые компьютеры?! (2017)

Визуализация:

# Динамическое программирование

- Прямой метод выполнения множественного выравнивания, обеспечивающий нахождение глобального оптимума.
- Для выравнивания  $N$  последовательностей требуется построение  $N$ -мерной матрицы. Таким образом, пространство поиска растет экспоненциально с ростом  $N$  и также зависит от длины последовательностей, а время поиска может быть оценено как  $O(L^N)$ .

A-BD-E-  
ACB--E-  
A--DCEE



# Деревья: определения

**Граф** – структура, содержащая вершины, соединенные ребрами.

Граф называется связным, если содержит хотя бы один путь между двумя любыми вершинами.

**Дерево** – связный граф, содержащий только один путь между двумя вершинами. Может быть укорененным и неукорененным.

**Двоичное дерево** – ориентированное дерево, в котором исходящие степени вершин (число исходящих рёбер) не превосходят 2.

**Длина ребра** – число, соотнесенное с каждым ребром и обозначающее, **в каком-то смысле**, расстояние между двумя вершинами, соединенными этим ребром.

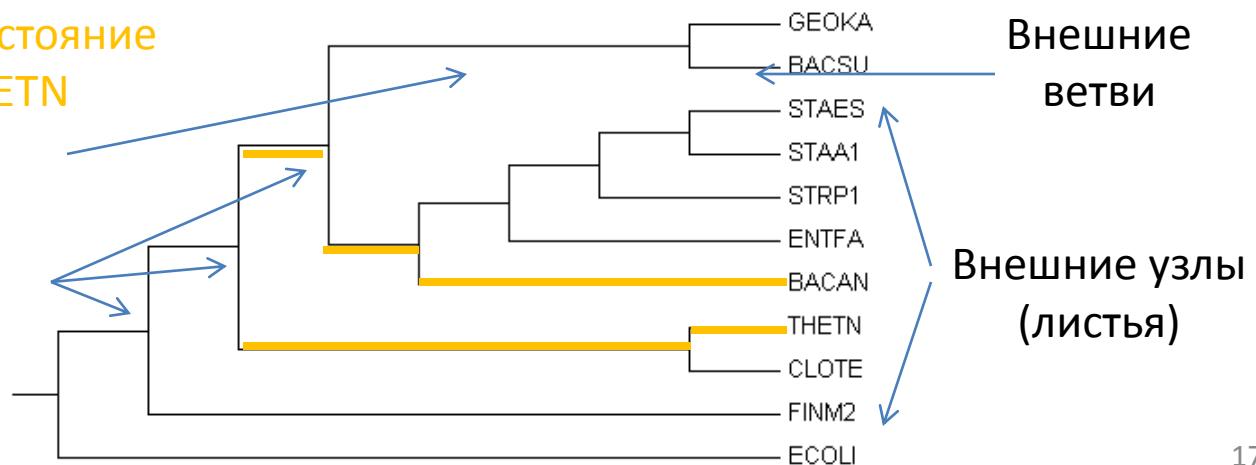
**Длина пути** – сумма всех длин ребер, составляющих путь.

Эволюционное расстояние  
между BACAN и THETN

Внутренние ветви

Внутренние узлы

Корень



# Деревья: свойства

Число деревьев

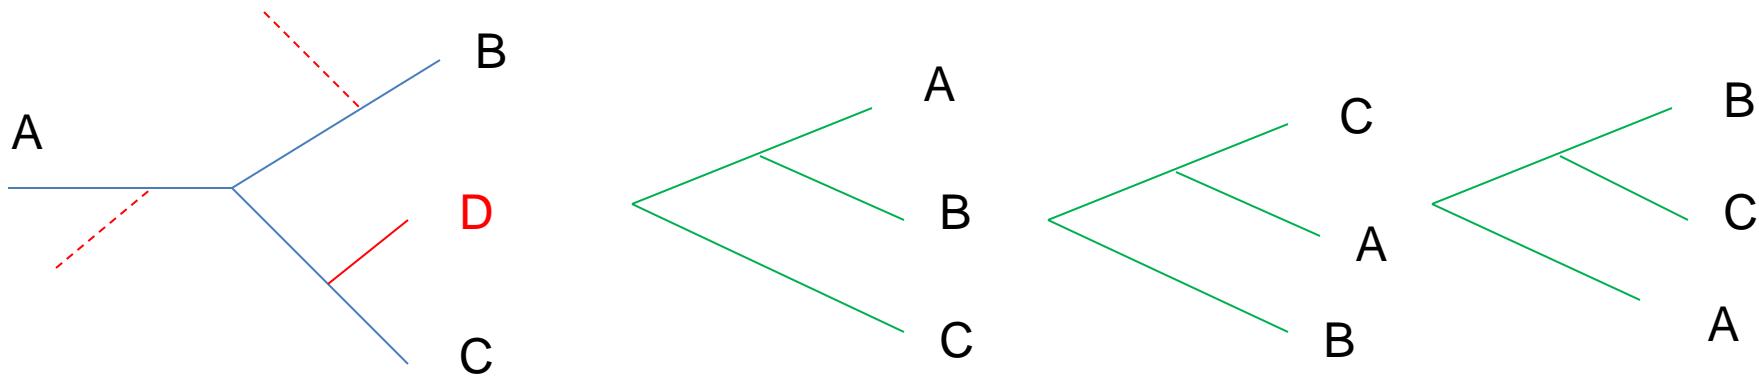
неукорененных

$$N_U = (2n - 5)!!$$

укорененных

$$N_R = (2n - 3)!!$$

С точки зрения филогении, правильное только одно!

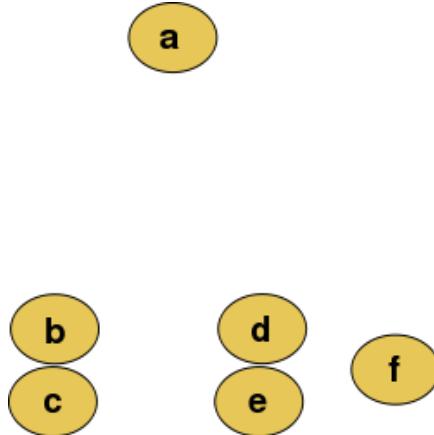


Кладограмма — филогенетическое дерево, не содержащее информации о длинах ветвей.

Филограмма — филогенетическое дерево, содержащее информацию о длинах ветвей; эти длины представляют изменение некой характеристики.

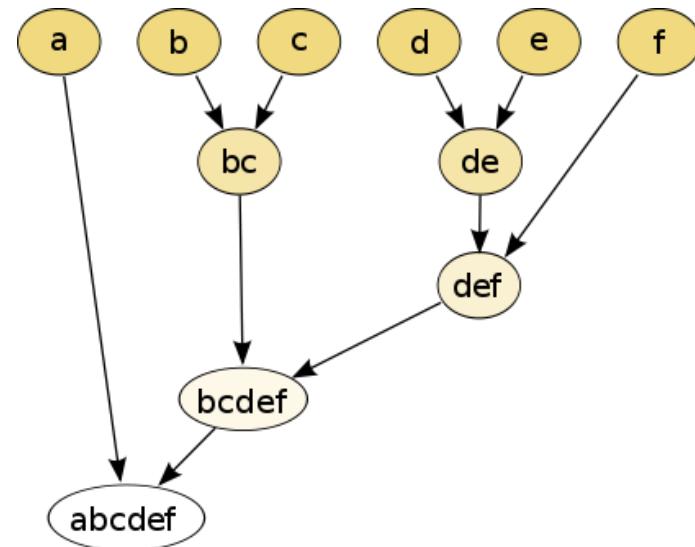
# Методы кластеризации. UPGMA

**UPGMA – Unweighted Pair Group Method with Arithmetic mean (1958)** – метод невзвешенной группировки с арифметическим средним – пример алгоритма иерархической кластеризации



Расстояние между элементами

Расстояние между кластерами



$$\|a - b\|_2 = \sqrt{\sum_i (a_i - b_i)^2}$$

$$\frac{1}{|\mathcal{A}| \cdot |\mathcal{B}|} \sum_{x \in \mathcal{A}} \sum_{y \in \mathcal{B}} d(x, y).$$

# Методы кластеризации. UPGMA

Дан набор объектов  $S_k$ , где для каждой пары  $(S_i, S_j)$  установлена мера сходства  $L(S_i, S_j)$ . Для построения дерева выбирают два наиболее близких объекта  $(S_m, S_n)$  и добавляют вершину, изображающую их общего «предка»  $(S_{mn})$ . Затем замещают эти два объекта группой, содержащей обоих, и присваивают расстояниям от этой пары до остальных объектов  $S_k$  средние значения от каждого из элементов этой группы до  $S_k$ :

$$L(S_{mn}, S_k) = \frac{L(S_m, S_k) + L(S_n, S_k)}{2}$$

В случае объединения кластеров  $C_i$  и  $C_j$  с образованием кластера  $C_k$ , содержащего  $n_i + n_j = n_k$  элементов, расстояние от кластера  $C_k$  до остальных кластеров  $C_m$  вычисляется как

$$L(C_k, C_m) = \frac{n_i L(C_i, C_m) + n_j L(C_j, C_m)}{n_i + n_j}$$

# Методы кластеризации. UPGMA

Дано 6 последовательностей – ATTTG, AGCGT, ACCGT, CGCGA, GGCGA, CGGGC.

Используя расстояние по Хэммингу, получаем матрицу расстояний:

| L     | ATTTG | AGCGT | ACCGT | CGCGA | GGCGA | CGGGC |
|-------|-------|-------|-------|-------|-------|-------|
| ATTTG | 0     | 4     | 4     | 5     | 5     | 4     |
| AGCGT |       | 0     | 1     | 2     | 2     | 3     |
| ACCGT |       |       | 0     | 3     | 3     | 4     |
| CGCGA |       |       |       | 0     | 1     | 2     |
| GGCGA |       |       |       |       | 0     | 3     |
| CGGGC |       |       |       |       |       | 0     |

# Методы кластеризации. UPGMA

Дано 6 последовательностей – ATTTG, AGCGT, ACCGT, CGCGA, GGCGA, CGGGC.

Используя расстояние по Хэммингу, получаем матрицу расстояний:

| L     | ATTTG | AGCGT | ACCGT | CGCGA | GGCGA | CGGGC |
|-------|-------|-------|-------|-------|-------|-------|
| ATTTG | 0     | 4     | 4     | 5     | 5     | 4     |
| AGCGT |       | 0     | 1     | 2     | 2     | 3     |
| ACCGT |       |       | 0     | 3     | 3     | 4     |
| CGCGA |       |       |       | 0     | 1     | 2     |
| GGCGA |       |       |       |       | 0     | 3     |
| CGGGC |       |       |       |       |       | 0     |

| L            | ATTTG | AGCGT, ACCGT | CGCGA       | GGCGA       | CGGGC       |
|--------------|-------|--------------|-------------|-------------|-------------|
| ATTTG        | 0     | (4+4)/2=4    | 5           | 5           | 4           |
| AGCGT, ACCGT |       | 0            | (2+3)/2=2,5 | (2+3)/2=2,5 | (3+4)/2=3,5 |
| CGCGA        |       |              | 0           | 1           | 2           |
| GGCGA        |       |              |             | 0           | 3           |
| CGGGC        |       |              |             |             | 0           |

# Методы кластеризации. UPGMA

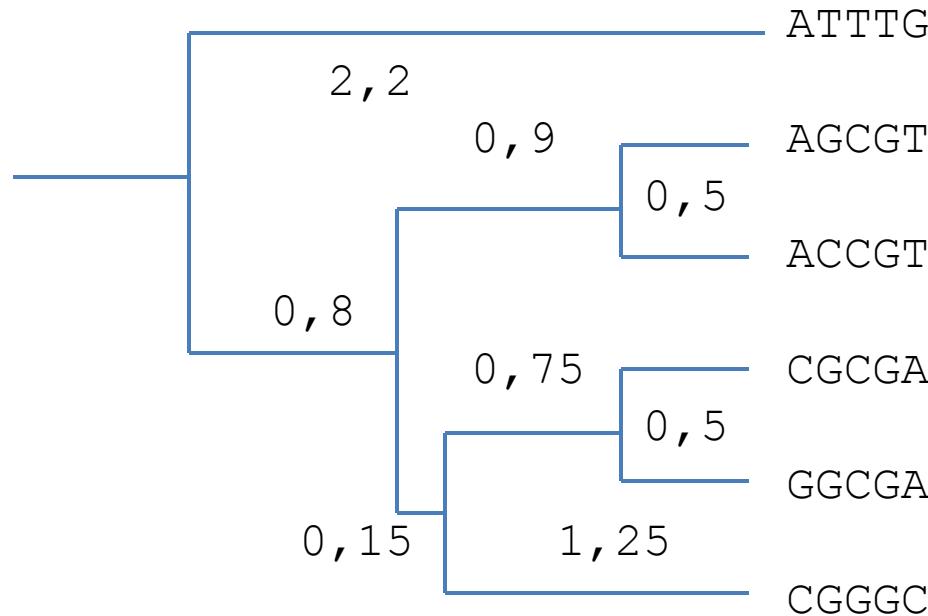
| L            | ATTTG | AGCGT, ACCGT | CGCGA, GGCGA      | CGGGC         |
|--------------|-------|--------------|-------------------|---------------|
| ATTTG        | 0     | 4            | $(5+5)/2=5$       | 4             |
| AGCGT, ACCGT |       | 0            | $(2,5+2,5)/2=2,5$ | 3,5           |
| CGCGA, GGCGA |       |              | 0                 | $(2+3)/2=2,5$ |
| CGGGC        |       |              |                   | 0             |

| L                     | ATTTG | AGCGT, ACCGT | (CGCGA, GGCGA), CGGGC |
|-----------------------|-------|--------------|-----------------------|
| ATTTG                 | 0     | 4            | $(2*5+4)/3=4,7$       |
| AGCGT, ACCGT          |       | 0            | $(2*2,5+3,5)/3=2,8$   |
| (CGCGA, GGCGA), CGGGC |       |              | 0                     |

|  |       |  |
|--|-------|--|
| L  | ATTTG | ((CGCGA, GGCGA), GGGC), (AGCGT, ACCGT) |
| ATTTG                                      | 0     | $(4*2+4,7*3)/5=4,4$                    |
| ((CGCGA, GGCGA), CGGGC),<br>(AGCGT, ACCGT) |       | 0                                      |

# Методы кластеризации. UPGMA

Объединяя теперь кластеры, получим дерево :

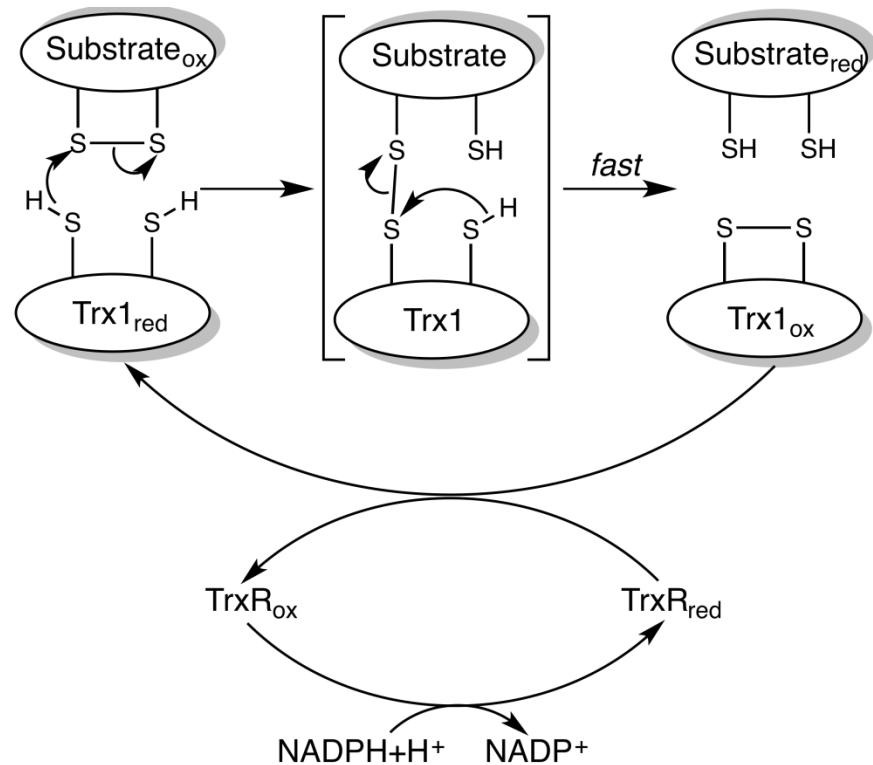


Длины ветвей установлены так, что расстояние от корня одинаково для всех листьев - ультраметричность.

Метод UPGMA подразумевает справедливость гипотезы молекулярных часов (постоянной скорости эволюции) (Э. Цукеркандль, Л. Полинг, 1962).

# Построение профилей

Тиоредоксины – семейство белков, отвечающих за восстановление дисульфидных связей в белках и встречающихся как в животном, так и в растительном мире.



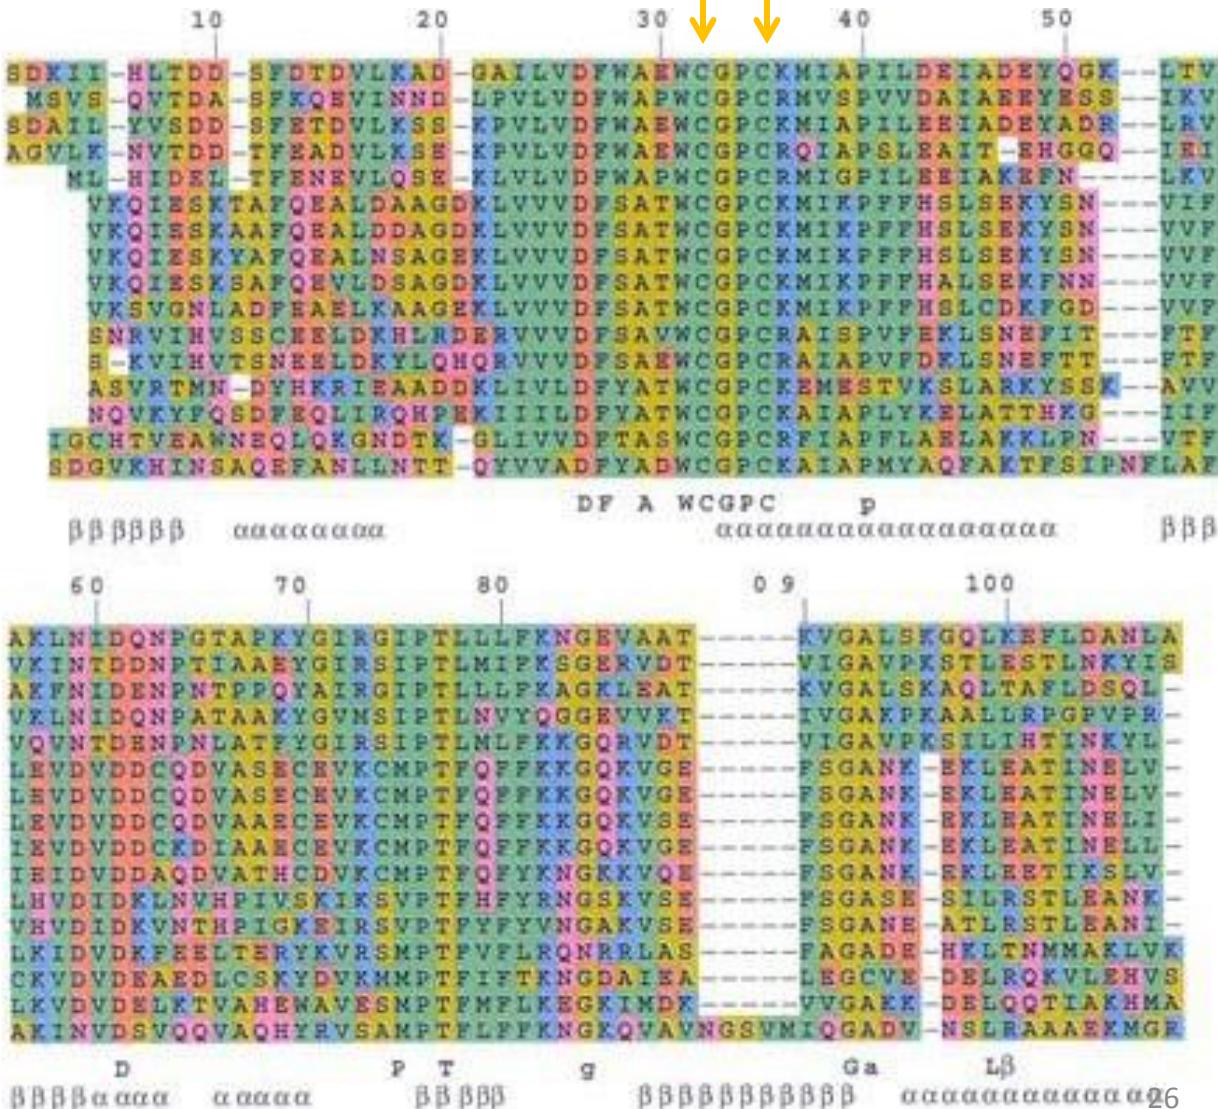
Выравнивание структур тиоредоксина человека и мушки *Drosophila melanogaster*.

# Построение профилей

Cys 32 Cys35

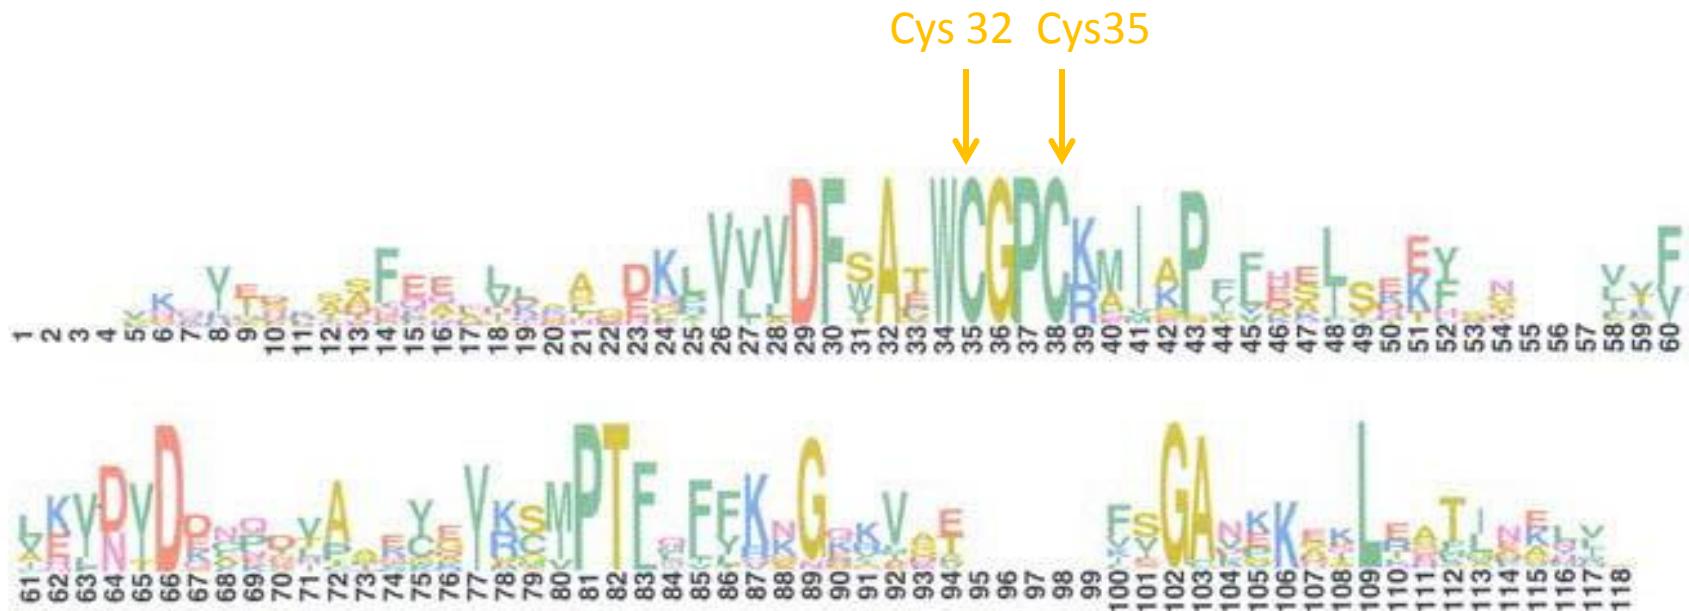
(a)

*Escherichia coli*  
*Porphyra purpurea*  
*Thiobacillus ferrooxidans*  
*Streptomyces clavuligerus*  
*Cyanidioschyzon merolae*  
 Human  
 Rhesus monkey  
 Sheep  
 Rabbit  
 Chicken  
*Dictyostelium discoideum*  
*Dictyostelium discoideum*  
*Drosophila melanogaster*  
*Caenorhabditis elegans*  
*Ricinus communis*  
*Neurospora crassa*



# Построение профилей

(b)



| Номер остатка | Число остатков каждой аминокислоты |   |    |   |    |   |   |   |   |   |   |   |   |   |   |   |   |    |   |    |
|---------------|------------------------------------|---|----|---|----|---|---|---|---|---|---|---|---|---|---|---|---|----|---|----|
|               | A                                  | C | D  | E | F  | G | H | I | K | L | M | N | P | Q | R | S | T | V  | W | Y  |
| 28 (25)       | 1                                  |   |    |   |    |   |   |   |   | 2 |   |   |   |   |   |   |   | 13 |   |    |
| 29 (26)       |                                    |   | 16 |   |    |   |   |   |   |   |   |   |   |   |   |   |   |    |   |    |
| 30 (27)       |                                    |   |    |   | 16 |   |   |   |   |   |   |   |   |   |   |   |   |    |   |    |
| 31 (28)       |                                    |   |    |   |    |   |   |   |   |   |   |   |   |   | 7 | 1 |   | 5  | 3 |    |
| 32 (29)       | 16                                 |   |    |   |    |   |   |   |   |   |   |   |   |   |   |   |   |    |   |    |
| 33 (30)       |                                    |   |    | 1 | 4  |   |   |   |   |   |   |   |   |   | 2 |   | 1 | 7  | 1 | 27 |

# Построение профилей

В реальности нужно учитывать, что встречаемость аминокислот не равновероятна, и использовать матрицы замен (**PSSM**).

## Применение:

- Аккуратное выравнивание дальноводственных последовательностей
- Выявление консервативных остатков и паттернов для:
  - предположения об активном центре или сайте связывания
  - идентификации и классификации родственных последовательностей
- Выявление вариабельных остатков для потенциальных замен (петли в антилерах)

Недостатком, очевидно, является то, что само выравнивание должно быть известно заранее.

# Прогрессивное выравнивание. Clustal

Clustal (1988) выполняет постепенное выравнивание все новых последовательностей, начиная с наиболее <эволюционно> близких, ориентируясь на предварительно построенное на основании парных выравниваний филогенетическое дерево.

**Алгоритм:**

- 1) Экспресс-оценка выравнивания двух последовательностей вычисляется как **число совпадающих остатков в словах длины K** ( $K = 1\text{-}2$  для белковых последовательностей и  $2\text{-}4$  для нуклеотидных) за вычетом штрафа за сделанные вставки.
- 2) Методом **UPGMA** (позже **NJ**) рассчитывается направляющее дерево, по которому затем рассчитываются веса последовательностей, причем более близкие последовательности получают меньшие веса.
- 3) Согласно направляющего дерева выбираются наиболее близкие последовательности и выполняется их выравнивание методом динамического программирования с использованием матрицы замен и штрафов за открытие/расширение вставок, с полученным выравниванием сопоставляются всё новые последовательности.

# Прогрессивное выравнивание. Clustal

Особое внимание удалено значениям штрафов за вставки. Введена их зависимость от:

- А) типа сопоставляемого и предшествующего остатков;
- Б) степени близости последовательностей;
- В) длин рассматриваемых последовательностей;
- Г) наличия вставок в уже имеющемся выравнивании;
- Д) характера аминокислотной последовательности.

One gap, always gap

Текущая версия - Clustal Omega - использует СММ

<http://www.ebi.ac.uk/Tools/msa/clustalo/>



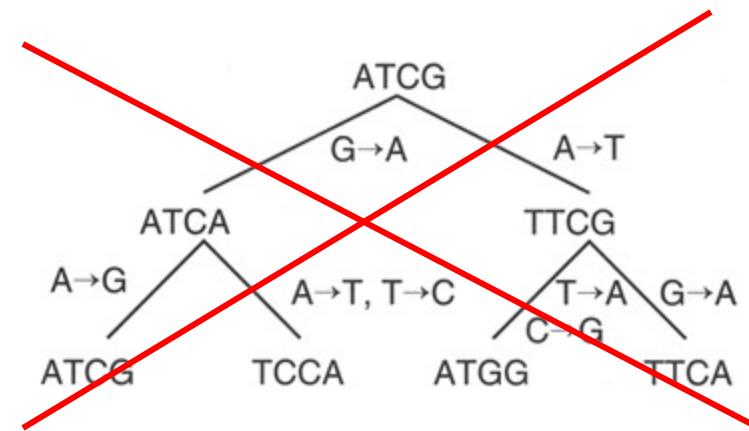
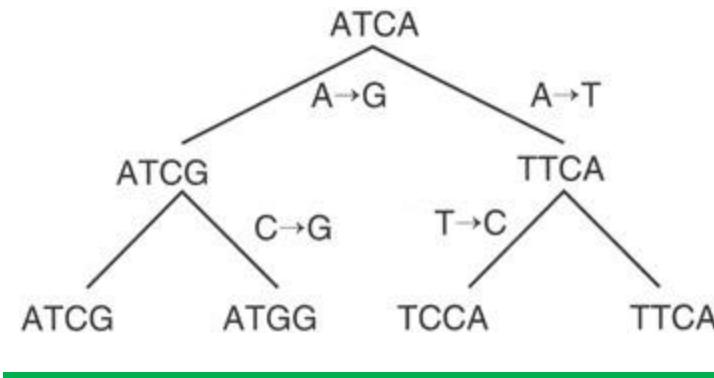
# Итеративное выравнивание. MUSCLE

Три стадии:

- 1) быстрое «черновое» множественное выравнивание (парные глобальные выравнивания; оценка сходства как доля совпадающих позиций; построение направляющего дерева методом UPGMA или NJ; прогрессивное выравнивание)
- 2) улучшенное множественное выравнивание (оценка сходства как доля совпадающих позиций в текущем множественном выравнивании; построение направляющего дерева через построение матрицы расстояний по Кимуре и ее кластеризацию; сравнение текущего дерева с построенным ранее; пересчет выравнивания для отличающихся узлов; повторение до сходимости)
- 3) уточнение выравнивания (удаление произвольного узла для разбиения дерева на два; построение профилей для каждого поддерева и их выравнивание; расчет суммы парных оценок в получающемся множественном выравнивании; перебор всех узлов от листьев к корню и выбор выравнивания с максимальной суммой)

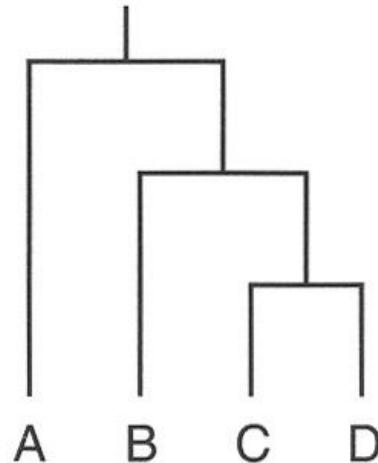
# Филогенетические деревья – методы

**Максимальная экономия** (Fitch, 1971) (метод оценки!) – критерий оптимальности, согласно которому **предпочтительнее деревья с меньшим суммарным числом мутаций**. Однако алгоритма быстрого построения такого дерева не существует.



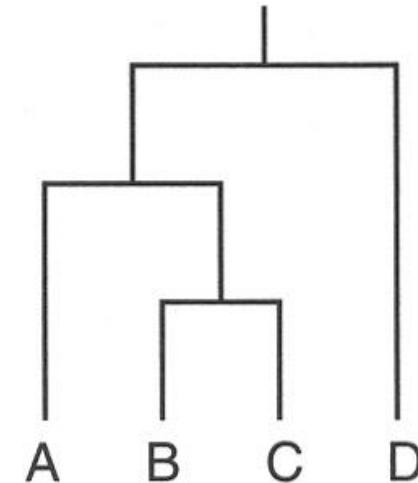
**Метод максимального правдоподобия** учитывает не просто число мутаций, но и их вероятность.

# Филогенетические деревья – проблема переменной скорости эволюции



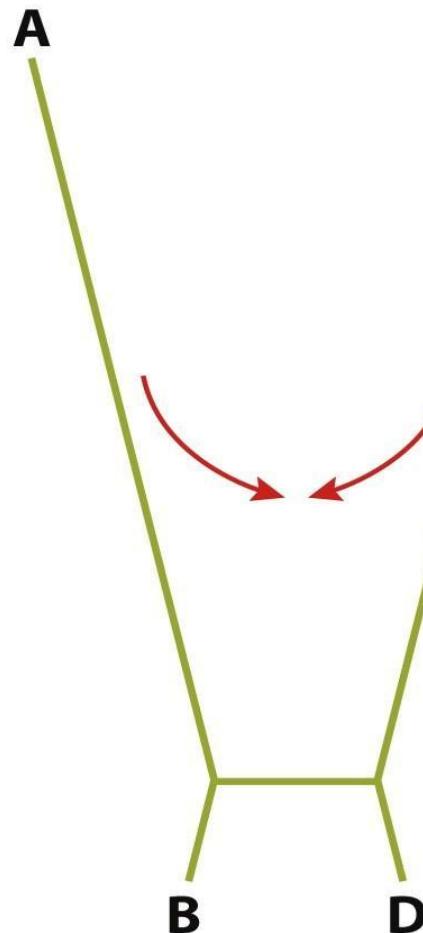
|   | A | B | C | D |
|---|---|---|---|---|
| A | 0 | 3 | 3 | 3 |
| B |   | 0 | 2 | 2 |
| C |   |   | 0 | 1 |
| D |   |   |   | 0 |

|   | A | B | C | D  |
|---|---|---|---|----|
| A | 0 | 3 | 3 | 20 |
| B |   | 0 | 2 | 20 |
| C |   |   | 0 | 20 |
| D |   |   |   | 0  |



# Филогенетические деревья – «притяжение длинных ветвей»

**True tree**



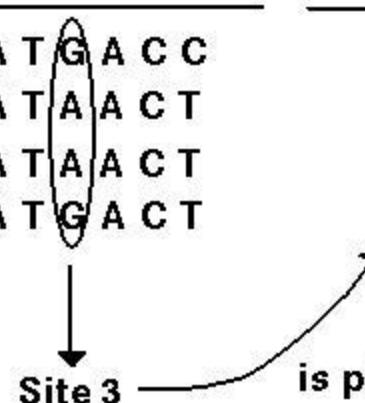
**Inferred tree**



# Филогенетические деревья – методы проверки

- 1) Использование внешней группы, т.е. видов, которые заведомо более удалены от всех видов, для которых строится дерево (приматы и корова);
- 2) Сравнение деревьев, полученных на основе разных характеристик. Очевидно, они должны быть согласованными;
- 3) Оценка результата с помощью формальных статистических тестов. Например, построение дерева для подмножества последовательностей из исходного множественного выравнивания должно дать поддерево дерева, полученного для этого выравнивания;
- 4) Бутстреп (boot strap)

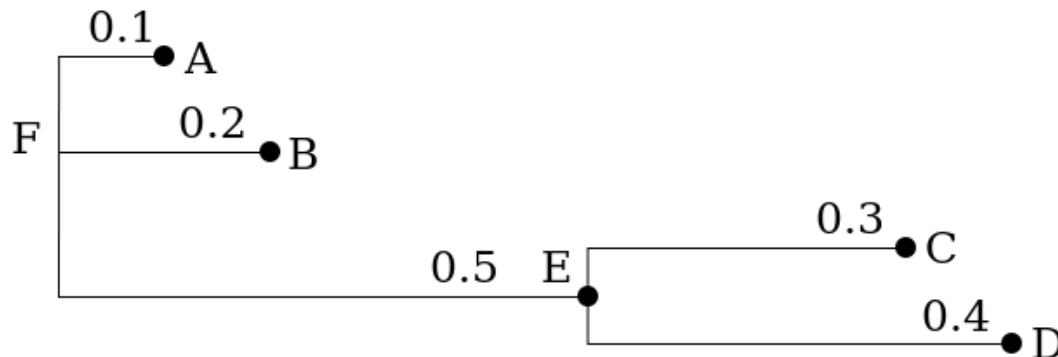
|       | Original sequence | Bootstrap Sequence |
|-------|-------------------|--------------------|
| Human | A T G A C C       | G T A A C A        |
| Rat   | A T A A C T       | A T A A C A        |
| Mouse | A T A A C T       | A T A A C A        |
| Chimp | A T G A C T       | G T A A C A        |

  
Site 3 is placed in first position

(Then the next five randomly chosen sites: 2, 1, 1, 5, 4, are placed in the next five positions.)

# Филогенетические деревья.

## Скобочная формула (Newick format) (1986)



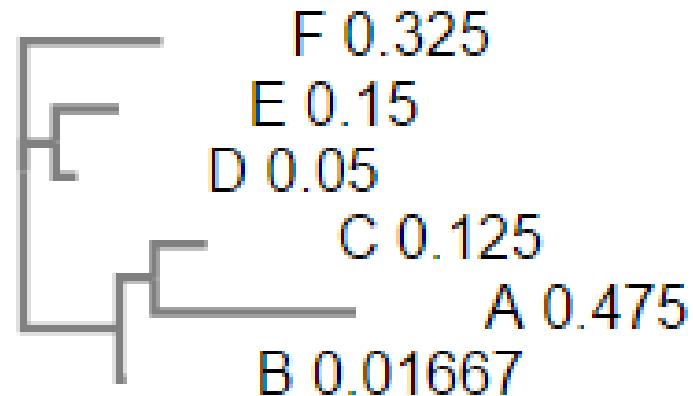
|                                    |  |
|------------------------------------|--|
| (,,(,));                           | <i>имена узлов не указаны</i>  |
| (A,B,(C,D));                       | <i>указаны только имена листьев</i>  |
| (A,B,(C,D)E)F;                     | <i>указаны имена всех узлов</i>  |
| (:0.1,:0.2,:0.3,:0.4):0.5;         | <i>для всех узлов кроме корня указано расстояние до родительского узла</i> |
| (:0.1,:0.2,:0.3,:0.4):0.5):0.0;    | <i>для всех узлов указано расстояние до родительского узла</i>             |
| (A:0.1,B:0.2,(C:0.3,D:0.4):0.5);   | <i>указаны имена листьев и расстояния</i>                                  |
| (A:0.1,B:0.2,(C:0.3,D:0.4)E:0.5)F; | <i>указаны все имена и расстояния</i>                                      |

# Филогенетические деревья. Скобочная формула (Newick format) (1986)

CLUSTAL O (1.2.1) multiple sequence alignment

```
(  
F:0.32500,  
(  
E:0.15000,  
D:0.05000)  
:0.07500,  
(  
(  
C:0.12500,  
A:0.47500)  
:0.08333,  
B:0.01667)  
:0.22500);
```

|   |       |
|---|-------|
| F | CGGGC |
| C | ACCGT |
| B | AGCGT |
| E | GGCGA |
| A | ATTTG |
| D | CGCGA |

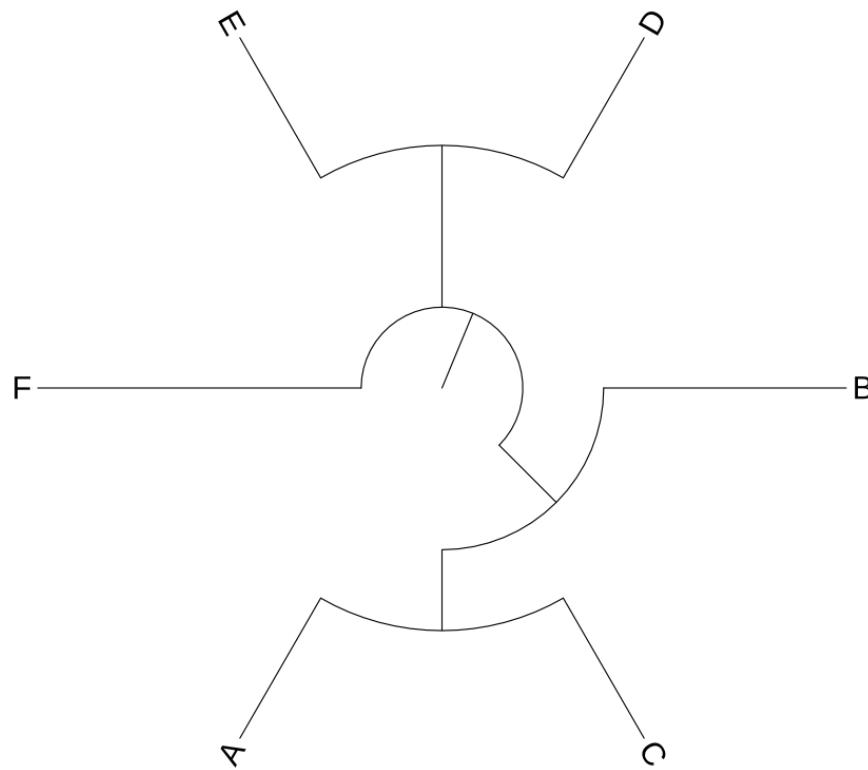


*This is a Neighbour-joining tree without distance corrections.*

# Филогенетические деревья. Круговое представление

CLUSTAL O (1.2.1) multiple sequence alignment

F CGGGC  
C ACCGT  
B AGCGT  
E GGCGA  
A ATTTG  
D CGCGA



```
(  
F:0.32500,  
(  
E:0.15000,  
D:0.05000)  
:0.07500,  
(  
(  
C:0.12500,  
A:0.47500)  
:0.08333,  
B:0.01667)  
:0.22500);
```

# Скрытые марковские модели

## A. Sequence alignment

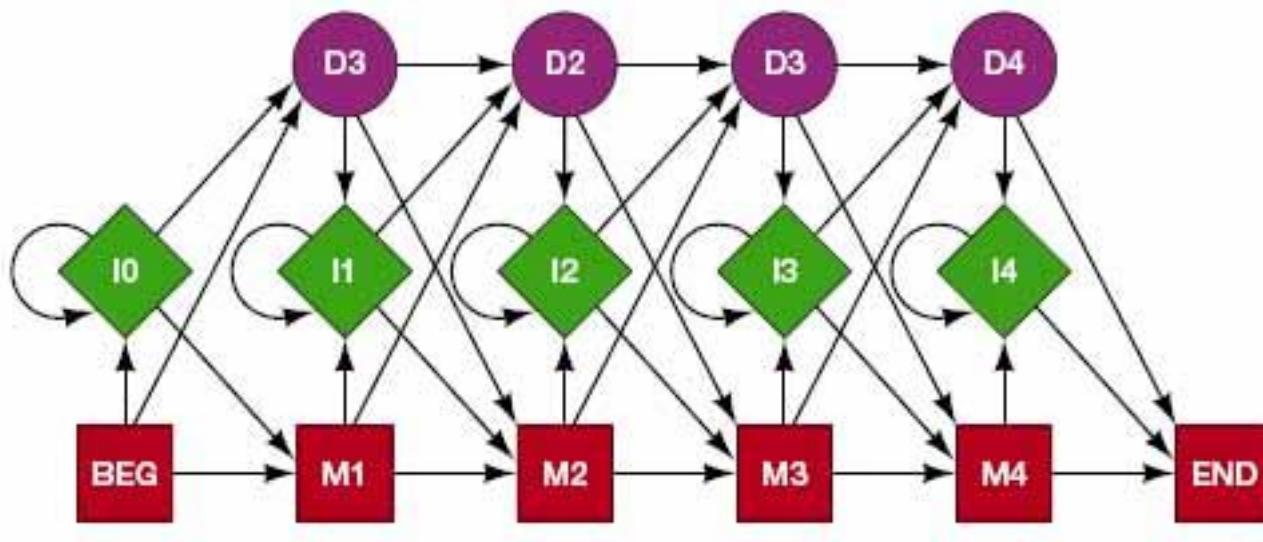
|   |   |   |   |   |
|---|---|---|---|---|
| N | . | F | L | S |
| N | . | F | L | S |
| N | K | Y | L | T |
| Q | . | W | - | T |

RED POSITION REPRESENTS ALIGNMENT IN COLUMN

GREEN POSITION REPRESENTS INSERT IN COLUMN

PURPLE POSITION REPRESENTS DELETE IN COLUMN

## B. Hidden Markov model for sequence alignment



■ match state

◆ insert state

● delete state

→ transition probability

# Скрытые марковские модели

## Алгоритм:

- Обучение. Имея ряд невыровненных последовательностей, можно выровнять их и подогнать вероятности переходов и порождения остатков, чтобы определить модель, описывающую данный набор последовательностей.
- Поиск гомологов. Имея модель и исследуемую последовательность, можно посчитать вероятность того, что модель могла бы сгенерировать эту последовательность. Если вероятность достаточно высока, то рассматриваемая последовательность принадлежит тому же семейству, что и обучающие.

# Скрытые марковские модели

## Алгоритм:

- Обучение. Имея ряд невыровненных последовательностей, можно выровнять их и подогнать вероятности переходов и порождения остатков, чтобы определить модель, описывающую данный набор последовательностей.
- Поиск гомологов. Имея модель и исследуемую последовательность, можно посчитать вероятность того, что модель могла бы сгенерировать эту последовательность. Если вероятность достаточно высока, то рассматриваемая последовательность принадлежит тому же семейству, что и обучающие.

ACA---ATC

TCAACTATC

ACAC--AGC

AGA---ATC

ACCG--ATG

Построим?

# Скрытые марковские модели

ACA---ATC

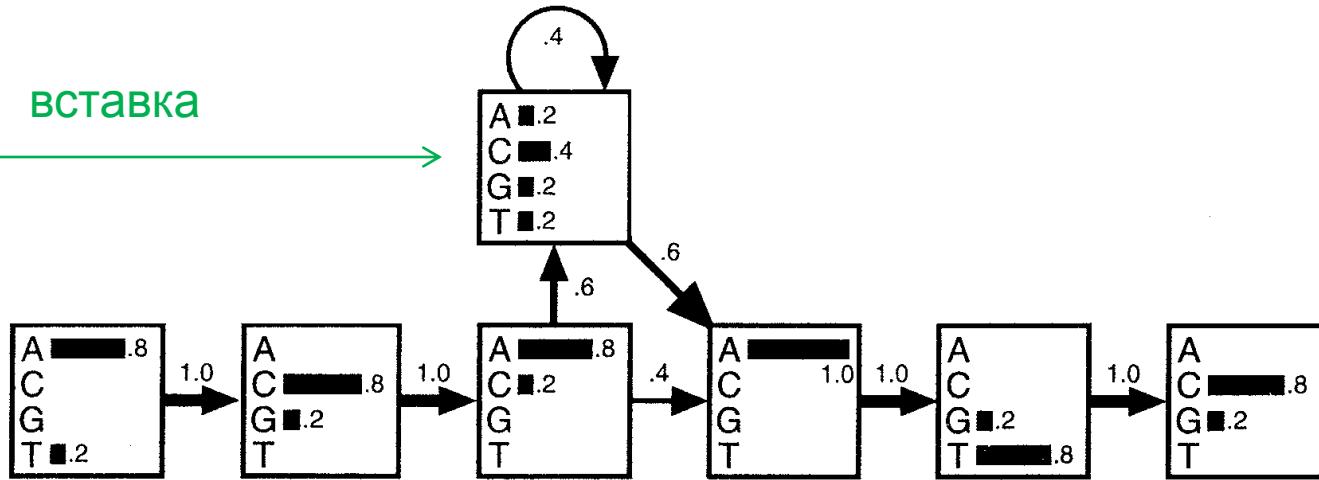
TCA~~A~~CTATC

ACAC~~C~~AGC

AGA---ATC

ACCG---ATG

вставка



# Скрытые марковские модели

ACA---ATC

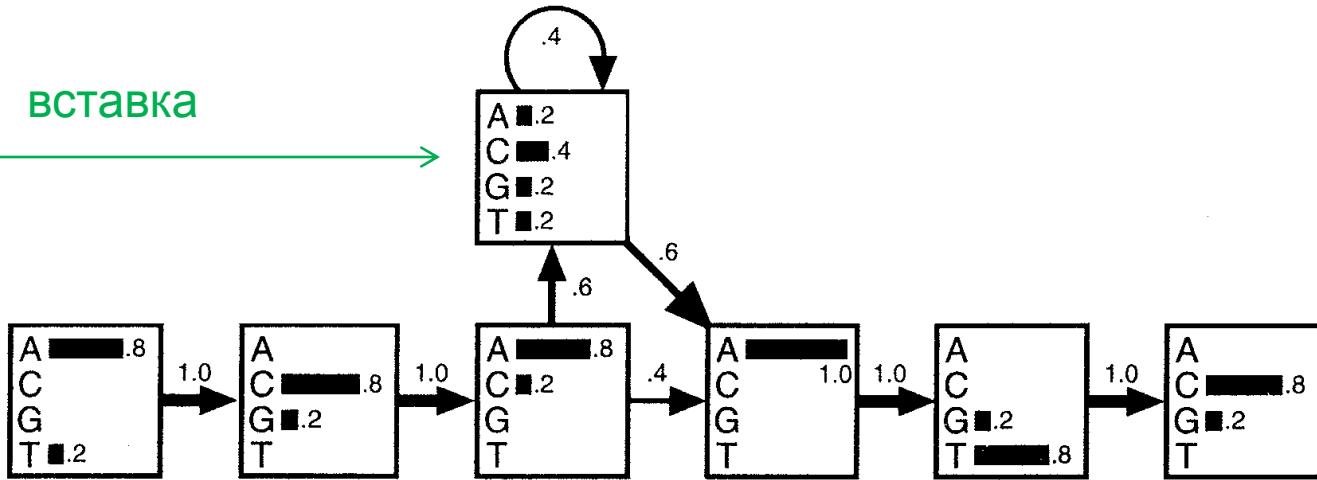
TCAACTATC

ACAC---AGC

AGA---ATC

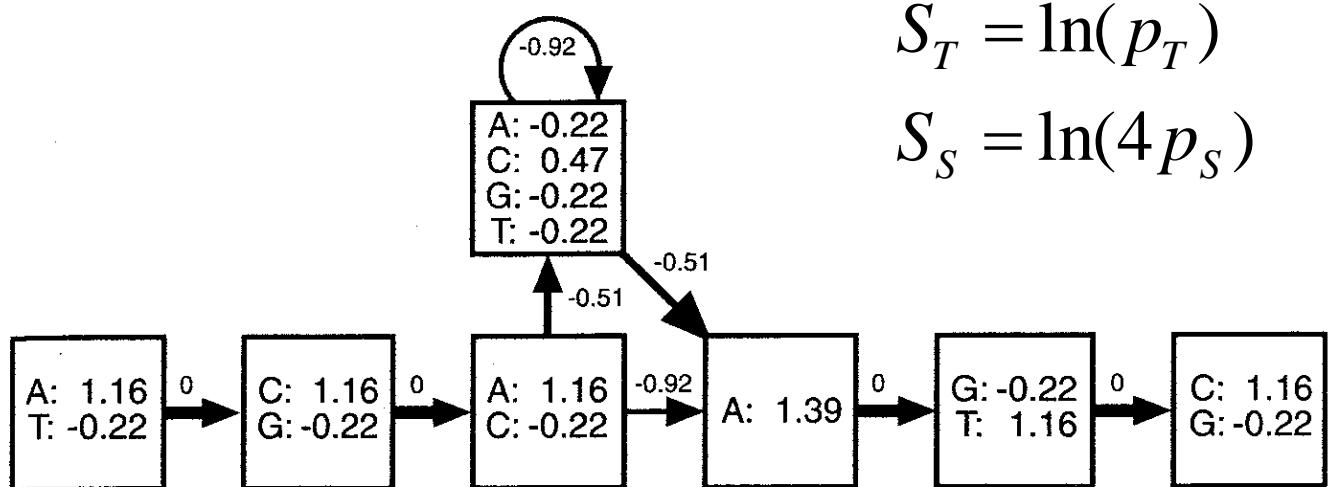
ACCG---ATG

вставка



$$S_T = \ln(p_T)$$

$$S_S = \ln(4 p_S)$$



# Скрытые марковские модели

ACA---ATC

TCAACATATC

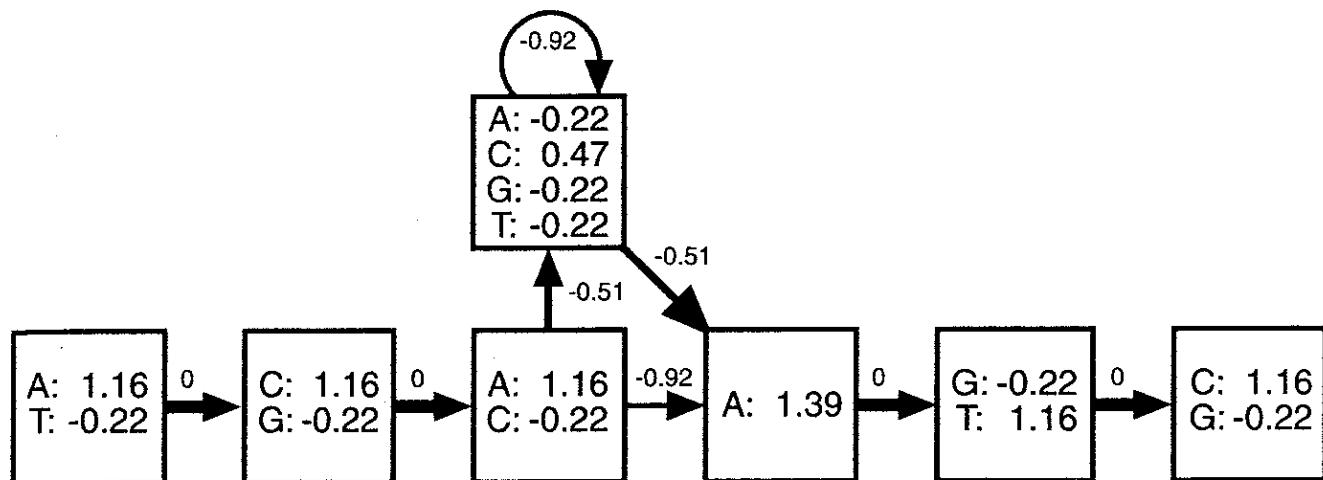
ACAC--AGC

AGA---ATC

ACCG--ATG

CGCGT-CGG

Посчитаем: описывает ли построенная модель новую последовательность?



# Скрытые марковские модели

$$\text{ACA---ATC} \quad S = 1.16 + 0 + 1.16 + 0 + 1.16 - 0.92 + 1.39 + 0 + 1.16 + 0 + 1.16 = 6.29$$

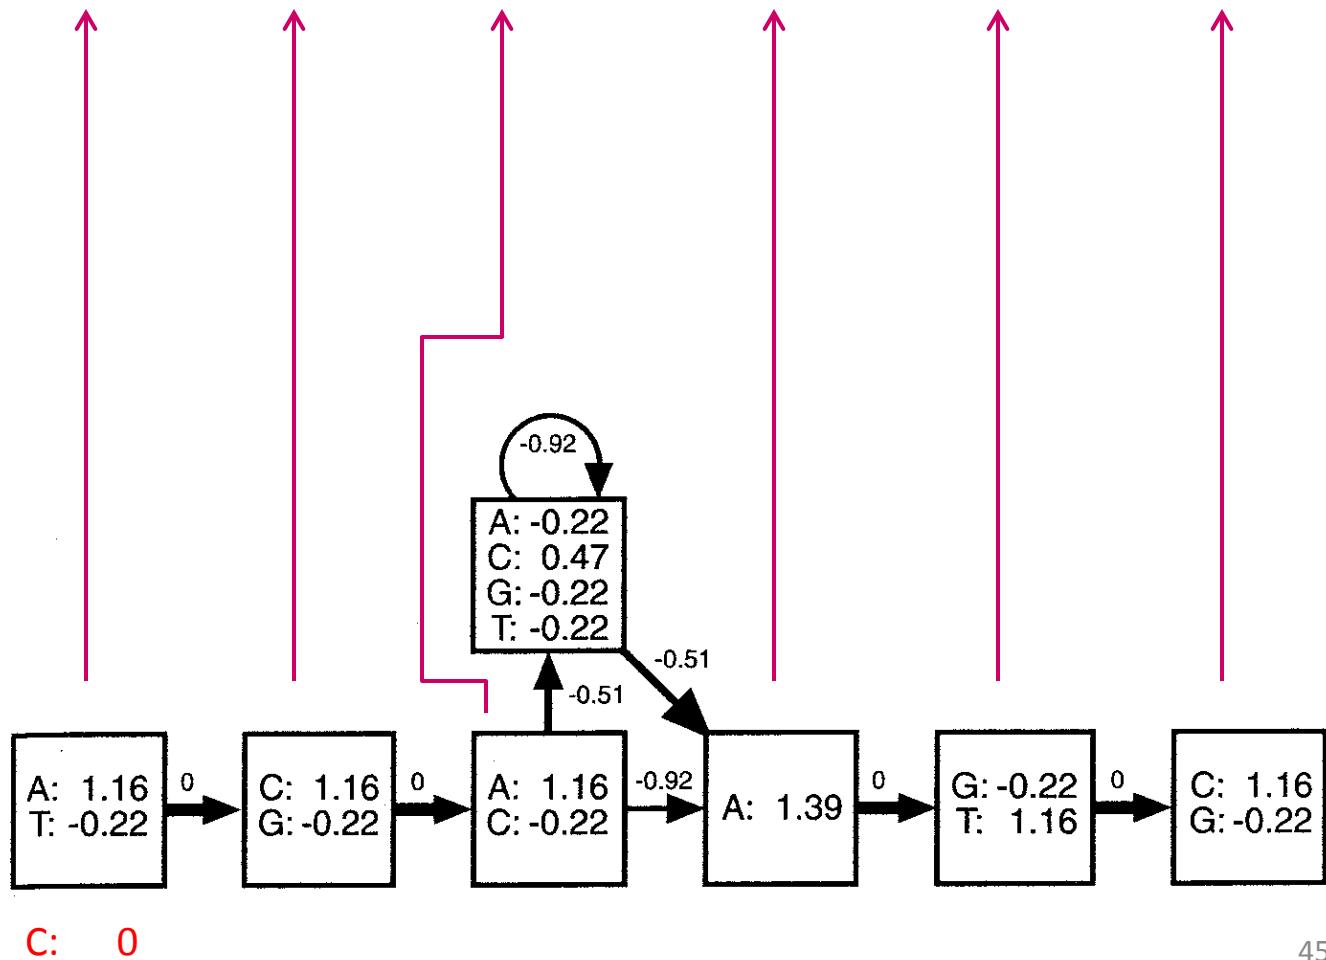
TCA~~A~~ACTATC ?

ACAC~~C~~--AGC

AGA~~G~~--ATC

ACCG~~G~~--ATG

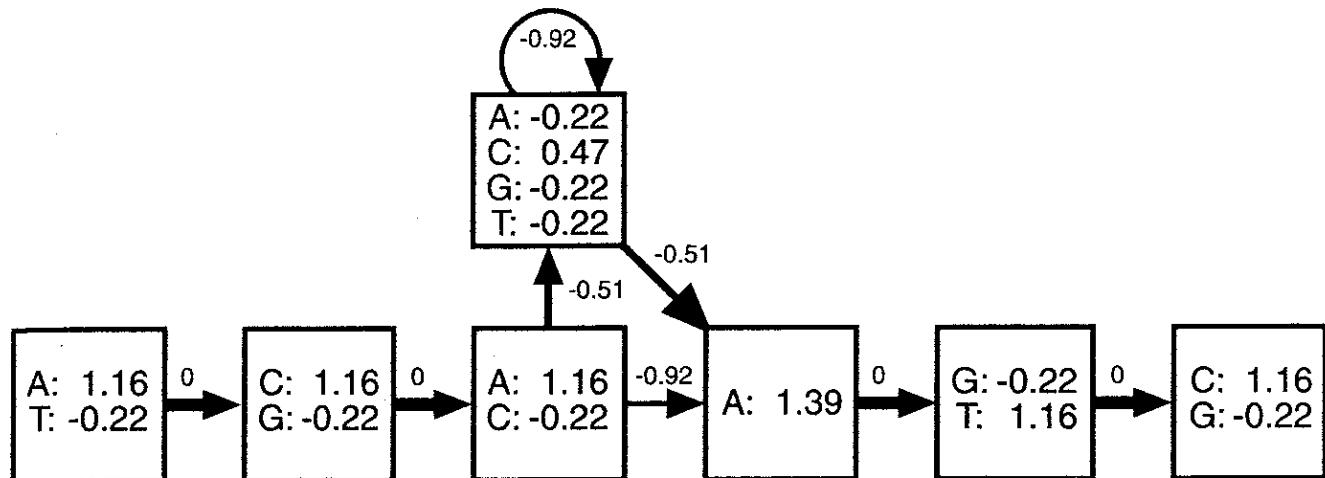
CGCGT-CGG ?



C: 0

# Скрытые марковские модели

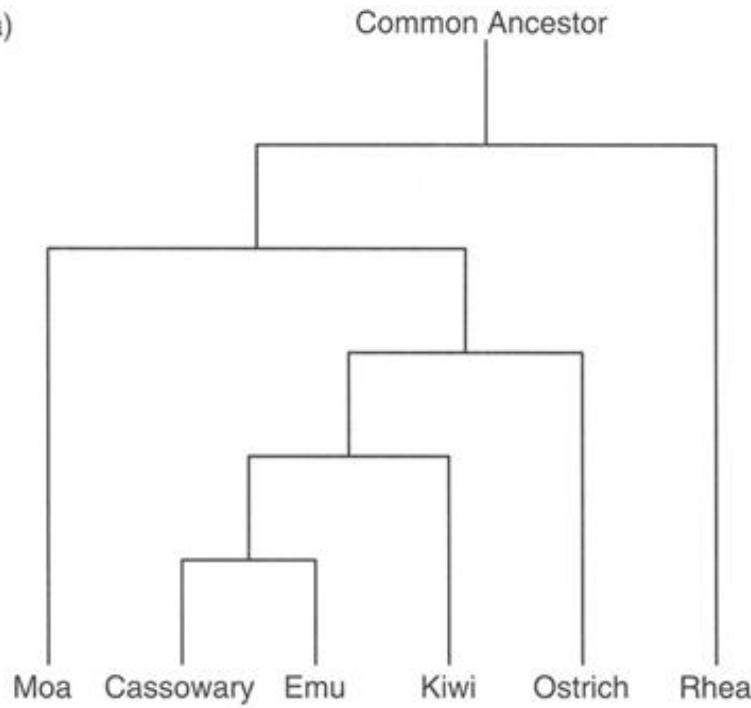
|           |        |
|-----------|--------|
| ACA---ATC | 6, 29  |
| TCAACTATC | 2, 99  |
| ACAC--AGC | 5, 26  |
| AGA---ATC | 4, 90  |
| ACCG--ATG | 3, 18  |
| CGCGT-CGG | -3, 28 |



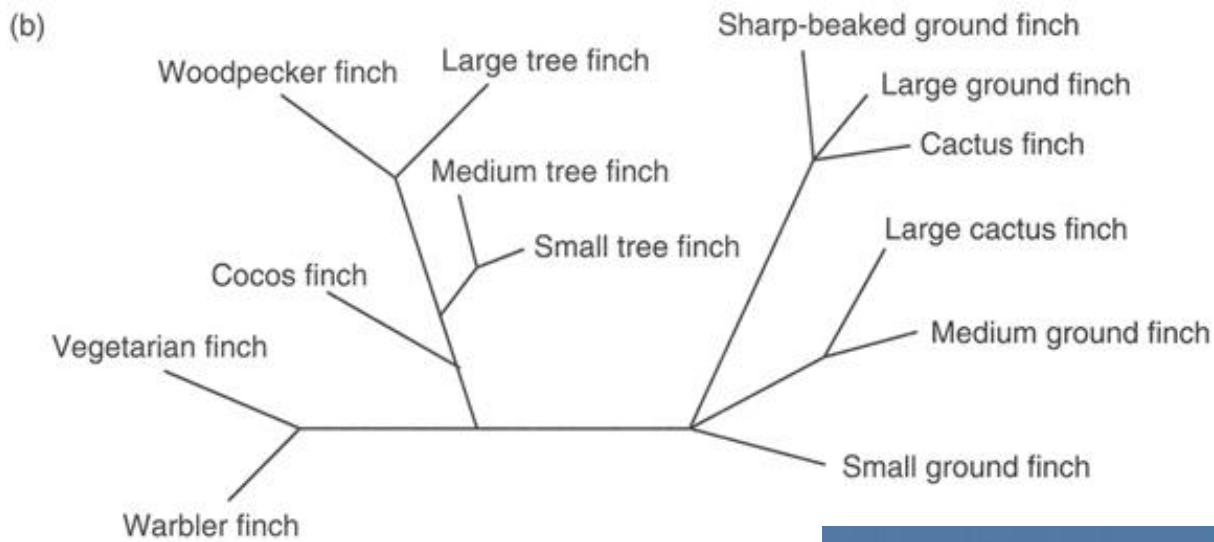
# Филогенетические деревья – примеры



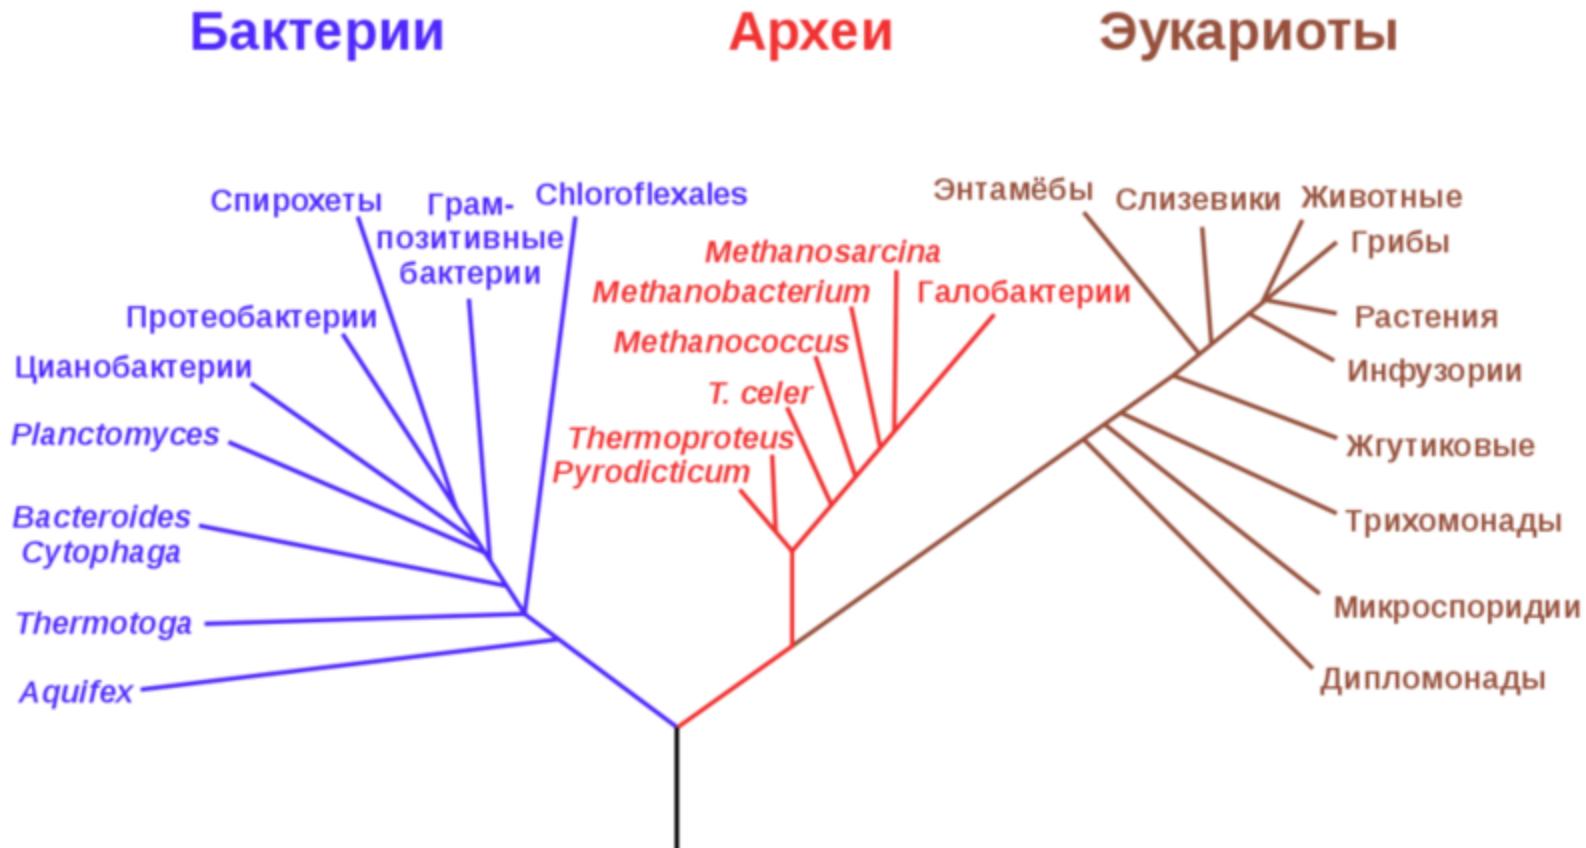
(a)



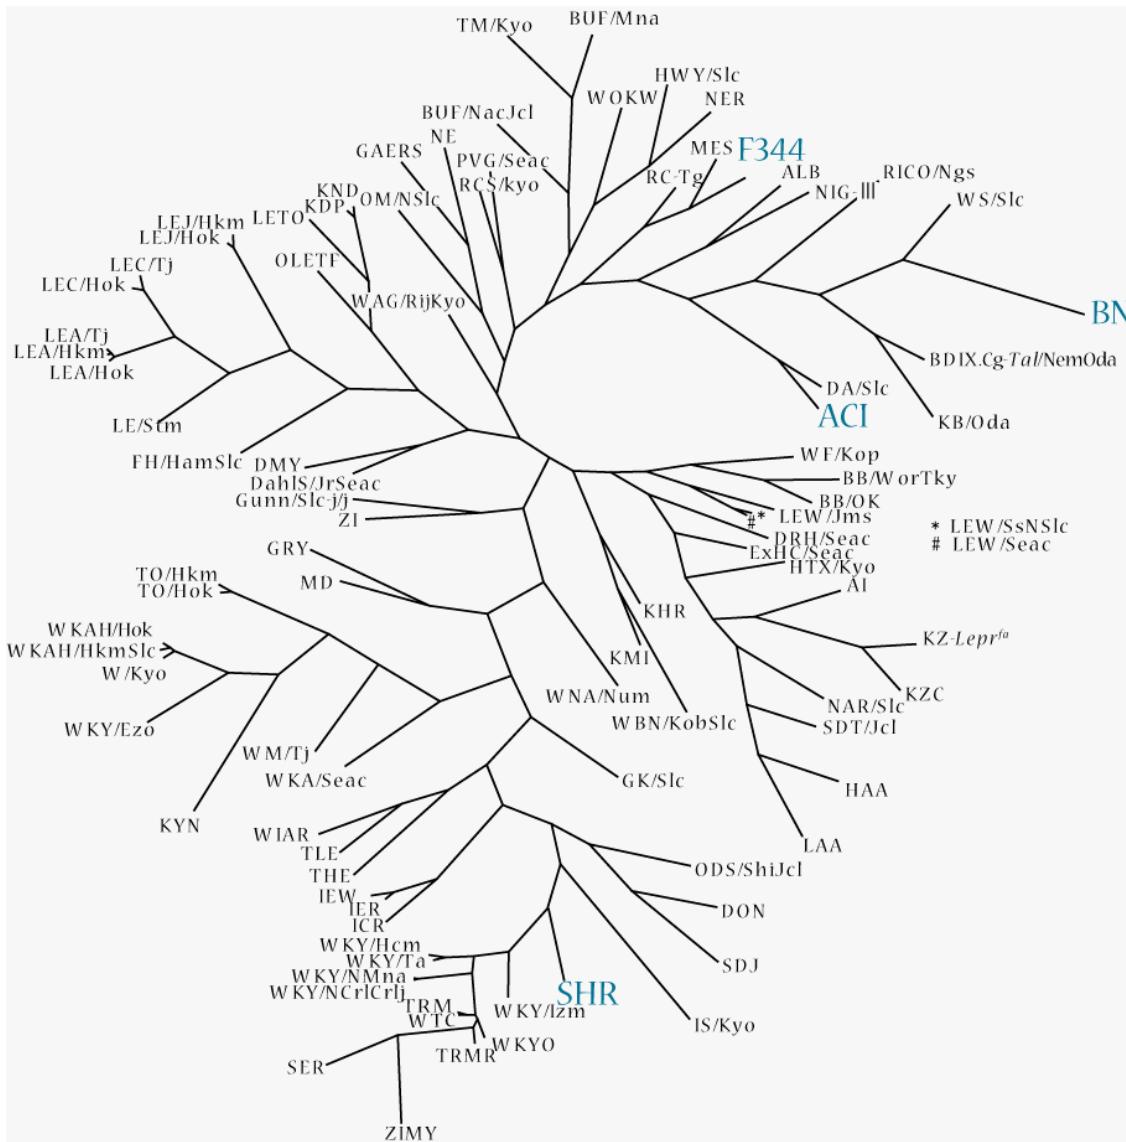
# Филогенетические деревья – примеры



# Филогенетические деревья – такие разные



# Филогенетические деревья – такие разные



# Филогенетические деревья – такие разные

