
Предсказание и дизайн структуры белков

— Моделирование по гомологии. Протягивание. Нейросети. —

Догма Анфинсена

Трёхмерная структура белка полностью определяется аминокислотной последовательностью






Figure 4-29 Principles of Biochemistry, 4/e
© 2006 Pearson Prentice Hall, Inc.



Проблемы фолдинга

- Для пептида длиной в 100 а.к. 3^N степеней свободы, получаем 10^{48} конформаций.
- **Парадокс Левинталя:** ”Промежуток времени, за который полипептид приходит к своему скрученному состоянию, на много порядков меньше, чем если бы полипептид просто перебирал все возможные конфигурации”.



Причины парадокса Левинталя

- Теоретические модели, не соответствуют тому, что природа старается оптимизировать;
- В ходе эволюции были отобраны только те белки, которые легко сворачиваются;
- белки могут сворачиваться разными путями, не обязательно следуя глобально оптимальному пути.
- Считается, что структура определяется последовательностью, но иногда нужны другие факторы.
- Структура более консервативна чем последовательность

Моделирование по гомологии (Сравнительное моделирование)

Гомологичные последовательности могут дать похожую структуру $\Rightarrow$ можно сэкономить время и взять гомологичную структуру как образец

- ищем гомологичный белок с известной структурой
- строим первичное выравнивание
- вторичное выравнивание $\rightarrow$ остов 3D структуры

Важно оценить вероятность, когда различия в последовательности могут привести изменению способа укладки

- улучшение выравнивания
- отдельное моделирование положения боковых цепей
- Проверка и исправление ошибок

Доступность шаблонов


- Сейчас известно порядка 2×10^5 структур. Примерно 10% это уникальные белки.
- Только 30% из первого пункта имеют разрешение лучше 3.0 ангстрем.
- Примерно 25% известных последовательностей можно использовать для сравнительного моделирования.
- Для 50% последовательностей можно предсказать способ укладки.

Поиск шаблона

- Поиск по PDB с помощью:
 - Blast
 - Psi-Blast
 - Методов распознавания упаковки
- Используя биологическую информацию.
- Функциональное аннотирование в базах данных.
- Используя информацию об активных сайтах, или мотивы.


Уточнение выравниваний

Template	I	C	R	L	P	G	S	A	E	A
1: Model (bad)	V	C	R	M	P	-	-	-	E	A
2: Model (good)	V	C	R	-	-	-	M	P	E	A






Выбор шаблона

- Лучший вариант не обязательно обладает лучшей степенью идентичности.
 - Белок 1: ID 93%, 3.5 ангстрема разрешение. Хуже.
 - Белок 2: ID 90%, 1.5 ангстрема разрешение. Лучше!




Оценка происхождения модели шаблона

- Необходимо соотнести локальное качество модели с выравниванием.
- Хорошо, если области с низкой идентичностью совпадают с “подвижными” областями.



Построение остова

- Генерируем координаты остова белка для остатков из совпавших с шаблоном областей.
- Не обязательно использовать координаты, могут подойти ограничения на расстояния.
- Modeller использует такие ограничения.



Моделирование петель и боковых радикалов

Эмпирическое моделирование


Поиск подходящего фрагмента по PDB

- ProMod3 (SwissModel), FREAD, DaReUS-Loop

Молекулярная механика

Монте Карло

Rosetta



Моделирование боковых радикалов

- Если идентичность последовательностей высока то можно ожидать высокую консервативность третичных контактов.
- Если анализ показывает, что важные контакты консервативны то:

Лучше оставить конформацию боковых радикалов из заготовки чем моделировать.

- Высокая точность моделирования достигается для боковых радикалов внутри глобулы.
 - Причина: в экспериментах остатки на поверхности более подвижны.
 - Вычислительное проще упаковать гидрофобные остатки, чем учесть полярные контакты и водородные связи с водой или с участием воды.

Улучшение модели

- Методы минимизации энергии.
- Моделирование молекулярной динамики
- Моделирование методом Монте-Карло.

Хорошее выравнивание не исправит плохой выбор белка заготовки.

Хорошее моделирование петель не исправит плохое выравнивание.

Проверка моделей

- Большинство программ для моделирования по гомологии выдают правильные значения для связей и валентных углов.
- Карта Рамачандрана в большинстве случаев для модели выглядит также, как для белка заготовки
- Проверка на ориентацию или положение заряженных остатков может быть полезна.
- Использование любых экспериментальных данных:
 - Остатки активного центра.
 - Места модификаций.
 - Места контактов.

Если нет подходящей модели-заготовки

Предсказание структуры белка ab initio

Молекулярную динамика


Моделирование отжига.

На основе фрагментов, Rosetta

Threading

Rosetta


- Метод использует информацию о предсказании вторичной структуры
- Сравниваем фрагменты от 3 до 9 остатков с библиотекой известных структур. Строим эти фрагменты.
- Соединяем эти фрагменты и используем Монте-Карло для оптимизации третичной структуры.



Rosetta

При оптимизации используют эмпирические потенциалы

- Потенциалы для образования контактов
- Гидрофобный потенциал
- Потенциал для уменьшения радиуса гирации
- Оптимизация водородных связей
- Дисульфидные связи



Threading (протягивание)


- Сравнение последовательности с библиотекой укладок (например SCOP).
- Используем потенциалы для определения тенденций в известных способах укладки.
 - Каждую аминокислоту из модели помещаем в позиции белков разных укладок
 - Определяем как хорошо эта аминокислота подходит белку заготовке на основе парных взаимодействий
 - На основе суммарного результата определяем белок заготовку.

Threading (протягивание)

Target sequence

MTESVFAVVVTHRRPDELAKSLDVLTAQTRLPDHLIVVDNDGCGDSPVRELVAGQPIATTYLGSRRN
LGGAGGFALGMLHALAQGADWVWLADDDGHAQDARVLATLLACAKEYSLAEVSPMVCNIDDP
RLAFPLRRGLVWRRRASELRTAEGQELLPGIASLFNGALFRASTLAAIGVPDLRLFIRGDEVEMHRRLI
RSGLPFGTCLDAAYLHPCGSDEFKPILCGRMHA


1) 3D-fold calculation based on known structures



2) Model quality evaluation


"Quality" scores
residue-residue, residue-solvent interaction, ...

3) The best model selection



i-Tasser

Phyre2




Позволяет находить дальних далеких гомологов.

Способен предсказывать модели при идентичности менее 15%


AlphaFold 1

Не предсказывал структуру, а предсказывал дистограмму.

Схоже с тем, что делают в ЯМР и моделированию по шаблону



AlphaFold 2




AlphaFold 3

Натренирован не только для белка

Нельзя использовать в коммерческих целях

Отличается в оценке качества!



ESMFold

Натренирован не
только для белка



Нельзя
использовать в
коммерческих
целях

Отличается в
оценке качества!

Protein language modeling

Pretraining self-supervision on sequences only.

Structure emerges in the internal representations of the network from the self-supervision.



Ресурсы

<https://swissmodel.expasy.org/interactive>

<https://alphafoldserver.com/>

colabfold - <https://github.com/sokrypton/colabfold>