

Биоинформатика



Секвенирование нового поколения **(NGS)**




Истина

Герасимов Евгений Сергеевич



ВКонтакте



The **Human Genome Project** (HGP) was one of the great feats of exploration in history - **an inward voyage of discovery** rather than an outward exploration of the planet or the cosmos; an international research effort to sequence and map all of the genes - together known as the genome - of members of our species, *Homo sapiens*. Completed in April 2003, the HGP gave us the ability, for the first time, to read nature's complete **genetic blueprint for** building **a human being**.

Проекты-конкуренты

IHGSC

(Фрэнсис Коллинз)

Проект ведется под NIH

Анонимные доноры, открытость
данных

Разработали стандарты качества
секвенирования

Проект положил начало таким
проектам, как ENCODE, 1000
геномов, НарМар

Nature

Крейг Вентер

Работал в NIH, занимался мРНК,
ввел EST

Президент Celera Genomics

Основатель TIGR


Создатель Синтии (первого
биосинтетического организма)

Создатель первого ассемблера и по
сути первого метода NGS

Science




1865




1952



1953




1990




the
human
genome


2001



1983



1977



1961

NGS

>2010




Проект "Геном человека"



25 тысяч генов




геном человека полностью
отсеквенирован




Структура ДНК




Нуклеотид в цепи



Полимеразная реакция



Включение нуклеотида




”По Сэнгеру”

ДНК секвенирование первого поколения

- Исторически **первый** метод секвенирования
- Как и практически все методы секвенирования основан на активности ДНК-зависимой **ДНК-полимеразы**
- В качестве способа детекции сигнала использовался метод **авторадиографии**
- Основан на вероятностном прерывании синтеза цепи в определенной позиции (**ddNTP**)


ddNTP не имеет гидроксила на 3' конце, поэтому продление цепи невозможно



”По Сэнгеру”: принцип метода

праймер **AGTC-**
матрица **■ TCAGATCTAGGTACTG**

ddATP	 AGTCTA AGTCTAGA AGTCTAGATCCA AGTCTAGATCCATGA
ddGTP	 AGTCTAG AGTCTAGATCCATG
ddCTP	 AGTCTAGATC AGTCTAGATCC AGTCTAGATCCATGAC
ddTTP	 AGTCT AGTCTAGAT AGTCTAGATCCAT



FASTA формат

A, G, T, C и другие буквы

>KE147310.1 Leishmania tropica L590 unplaced genomic scaffold
TCACAAATAACTGTGTCGGCGCATGGCTGTAAGGCGTGTGCCGCACGGCTGCCGCACCACGCGATGG
GGTCTGTGACAGGGGGCGAGGCAGTGATCTTGTGTTCTGTGGCGGAATGGCGACATTGAAGGAAAACGT
AATGACGAGCACCTCCCTACATCTTATAGACATACACGCAAACCTCAGGTTACGCATTAATGATT
ACGCACTTCTGCTTCTATAATGTTTCAGTGCTTATATGTGTGCGTGTGGTGCAGCGATGTGTGTT
GCCTCTCTTGTGCTTCTCGTCTGTCGTCTCGCCGTACTGCTATTGACGAAGACGGATGAAAC
GGTGCCGAAGAGCAAATCGTCCCCTGTTCAAGATCACTGGCTGAAAAGGTCGATAGCTGGAGGGCCGTT
CGCCGGACTTCGATGCCGCAGTCAGGCCATCGAGAAAAGATCACCCACCAAGATAAGTCCCCTT
CCTTGAGAGATGCGAATGGCGGAAGTGAGCATCGCGCGATATTAGAGACCCTGCGGACCAAGCTAC

5' AATGACGAGCACCTCCCTACATCTTATAGACATACACGCAAACCTCAGGTTACGCATTAATGATT 3'
3' TTACTGCTCGTGGAGGGATGTAGAATATCTGTATGTGCGTTGGAGTCCAATGCGTAATTACTAAG 5'



reverse & complement

5' GAATCATTAAATGCGTAACCTGAGGTTGCGTGTATGTCTATAAGATGTAGGGAGGTGCTCGTCATT 3'




”По Сэнгеру”: 96х



ABI Prism 3100

Автоматизация метода секвенирования методом Сэнгера: капиллярные машины.

Качество прочтения: с какой вероятностью нуклеотид в данной позиции прочитан с ошибкой



Ошибки секвенирования

Источники ошибок

На этапе секвенирования образца

Обусловлены особенностями измерительной системы прибора и технологиями секвенирования

Можно выявить или предсказать.

На механизме предсказания ошибки основано присвоение качества прочтения основания прибором.

На этапе пробоподготовки

Вызваны присутствием нецелевых молекул в образце, ошибками ферментов (полимеразы)

Нельзя выявить на этапе секвенирования


Качество прочтения нуклеотида может быть выражено вероятностью ошибки. Принятый сегодня способ записи **Phred Score (Q)**.

$$Q = -10 \log_{10} P \quad \longrightarrow \quad P = 10^{-\frac{Q}{10}}$$

Phred Quality Score	Probability of incorrect base call	Base call accuracy
10	1 in 10	90%
20	1 in 100	99%
30	1 in 1000	99.9%
40	1 in 10000	99.99%
50	1 in 100000	99.999%


Теория поколений

быстрее, больше, дешевле





Пиросеквенирование

"Roche" 454: прочтение с огоньком









Пиросеквенирование




Пиросеквенирование

Молекулярные колонии на нанопланетах




Ошибки секвенирования

погрешность измерения





I



Ошибки секвенирования

погрешность измерения



Illumina



"Sequencing-by-Synthesis"


Sample
Prep

Cluster
Generation

Sequencing


Структура ампликона

Рождение молекулярного шедевра




Как добиться того, чтобы молекула ДНК неизвестной последовательности "читалась" лишь с одной определенной стороны?

Лигировать так называемый Y-адаптор амплифицировать с праймера




реальный ампликон Illumina обычно сложнее:




Генерация кластеров

Молекулярные основы ландшафтного дизайна




Bridge amplification

and single strand cut



Секвенирование через синтез

Ёлочка, гори!





Sequencing by synthesis

Illumina

d


Sequencing by synthesis



Detect color from flow cell


Ошибки секвенирования

Illumina




Полупроводниковое секвенирование

pH метр высокого разрешения




Секвенирование через лигирование

a




b







c

Input color sequence with a known base in red



Oxford Nanopore




H

1D Temp 5' - **GTGCATT-G-CTTGAGTTCTTT-CAGTT-A-**3'
2D 5' - **CTGCATTCTCCGTGAATTCTTCGAATTCT-**3'
1D Comp 5' - **TCGC-TT-TCCCGCGAATTCCCTT-GAATT-C-**3'

Pacific Biosystems

Читать молекулы в реальном времени

Pacific Biosciences — Real-time sequencing



Сравнение платформ

Тип	454		Ion		Solexa (Illumina)				SOLiD	PacBio	
	Junior	FLX	Torrent	Proton	HiSeq	MiSeq	NextSeq	5500	RSII	Sequel	
Длина чтения, bp	400	800	400	200	2x150	2x300	2x150	2x60	10-15kb	10-15kb	
Объем данных, Gb	0,035	0,7	2	16	180	15	129	150	1	10	
Цена за 1Mbp, \$	22	7	0,6	0,02	0,05	0,14	0,03	0,07	0,4	0,09	
Цена инструмента, тысяч \$	125	500	50	149	740	125	250	600	700	350	
Цена за запуск, \$	1100	6200	939	1000	6145	1600	4000	10503	400	850	
Время работы	10	24	7	4	40	65	29	8 days	0,5-6	0,5-6	
Частота ошибок, %	1	1	0,5-2,5	0,5-2,5	0,1	0,1	0,1	--	14	14	
Тип ошибок	индели	индели	индели	индели	замены	замены	замены	замены	индели	индели	

Спасибо за внимание